AI1 · Transformers por dentro

Atención · tokenización · GPT mínimo en PyTorch

AI Surfer · N3-AI Engineering

Mapa del módulo

Pieza	Pregunta que responde
Tokenización (BPE)	¿Cómo pasa el texto a enteros?
Atención	¿Cómo "entiende" cada token a los demás?
Bloque transformer	¿Cómo se apilan atención + MLP?
Entrenamiento	¿Qué se predice y con qué pérdida?
GPT mínimo	¿Puedo escribirlo yo en PyTorch?
Hugging Face	¿Cómo se usa un modelo preentrenado?

Tokens: del texto a los IDs

- Caracteres: secuencias larguísimas
- Palabras: vocabulario enorme
- **BPE (subwords)**: balance — el estándar de GPT/LLMs

BPE fusiona iterativamente el **par de tokens más frecuente**.

Atención: cada token pregunta y responde

Query · Key · Value

- **Q** (query): qué busca el token
- **K** (key): qué ofrece para ser buscado
- **V** (value): el contenido que se trasmite

```
Atención(Q,K,V) = softmax(QKᵀ/√d)·V
```

La escala por $\sqrt{d}$

- Los productos dot crecen con d
- Softmax con scores grandes → hiperpuntual → gradiantes atascados
- $/\sqrt{d}$ mantiene los scores en un rango "sano"

Máscara causal

- El token i **no puede** ver el futuro
- `-inf` por encima de la diagonal → softmax → peso 0
- Es lo que separa a **GPT** (autoregresivo) de **BERT** (bidireccional)

Bloque transformer

```
x ← x + Atención(Norm(x))    # mezcla ENTRE tokens
x ← x + MLP(Norm(x))         # cómputo POR token
```

- Residual: el gradiente fluye con profundidad
- LayerNorm: estabilidad

Entrenamiento: predicir el siguiente token

- Entrada: $[t_1 \dots t_n]$ → objetivo: $[t_2 \dots t_{n+1}]$
- Pérdida: **cross-entropy** (distribución sobre el vocab)

> No MSE: la salida es categorical, no un número.

El notebook: GPT mínimo

- ~70k parámetros, 2 capas, 4 cabezas, ctx=32
- Entrena en CPU en <1 min con corpus de 24 frases
- **Exactamente el mismo diagrama que GPT-4** — menos escala

Hugging Face (opcional, Colab)

```
tok = AutoTokenizer.from_pretrained("gpt2")
model = AutoModelForCausalLM.from_pretrained("gpt2")
model.generate(**tok(text, return_tensors="pt"))
```

En AI5 volvemos con LoRA/QLoRA para ajustarlo a tu caso.

Resumen

BPE → atención causal → bloques → cross-entropy → escalar

Lo que sigue: aplicaciones con LLMs (AI2) y RAG/agentes (AI3).