AI6 · Alineación y post-entrenamiento

Preferencias · DPO · GRPO · reproducibilidad

AI Surfer · N3-AI Engineering

Por qué este módulo

- Nicho de plus salarial: RLHF, DPO, RL con recompensas verificables
- Se valora: entender qué optimiza cada método, **detectar reward hacking**, experimentos **reproducibles**
- Entregable: un experimento de alineación con registro y evaluación

El pipeline

```
Base → SFT → Preferencias (DPO / RLHF) → RL verificable (GRPO)
```

Método	Necesita
DPO	pares chosen/rejected + π_ref
RLHF/PPO	RM + crítico + RL
GRPO	función de recompensa verificable

Datos de preferencias

```
{"prompt": [...], "chosen": [...], "rejected": [...]}
```

- Misma instrucción, `chosen ≠ rejected`
- Longitudes equilibradas
- Cuidado: autopreferencia y verborrea del juez

Modelo de recompensa

$$P(a > b) = \sigma(r(a) - r(b))$$

$$L = -\log \sigma(r(\text{chosen}) - r(\text{rejected}))$$

Gradiente: $-\sigma(-\Delta r)\cdot(x_w - x_l)$ — verificado contra autograd.

El RM hereda el **sesgo** de sus etiquetas.

Reward hacking

- El RM es un **proxy**
- Best-of-N: la puntuación sube, la utilidad real no la sigue
- La longitud tiende a 1: el modelo se vuelve verboso
- Defensas: KL, datos equilibrados, evaluación independiente

DPO

```
L = −log σ( β [ (log π − log π_ref)_w − (log π − log π_ref)_l ] )
```

- Sin RM ni RL: pérdida supervisada sobre pares
- **β grande ⇒ conservadora** (KL bajo) · β pequeño ⇒ se aleja
- Verificado: log 2, gradiente analítico, `gradcheck`

Barrido de β (juguete)

β	KL	utilidad real
0,05	alto	alta
1	medio	media
5	≈ 0	≈ referencia

Elige β mirando KL **y** tu evaluación.

GRPO

1. Muestrear un **grupo** de G respuestas
2. Recompensas **verificables** (JSON válido, campos, total exacto)
3. Ventaja = `(r − media)/(std + ε)` — sin crítico
4. `−E[A·log π] + β_KL·KL`

Grupo con recompensas iguales ⇒ ventaja 0 ⇒ sin señal.

Reward hacking en directo

Recompensa	Política aprende
formato + brevedad	`{}` (98 %)
+ campos + exacto	respuesta correcta (98 %)

Se arregla **la recompensa**, no entrenando más.

Registro reproducible

- Config inmutable · semilla · huella SHA-256 de los datos
- `run_id` = hash de la config · JSONL
- Test: **misma config ⇒ mismas métricas**
- Evaluar contra el modelo de partida (AI4) y mirar efectos secundarios

En Colab

`DPOTrainer` (columnas prompt/chosen/rejected, `beta`) · `GRPOTrainer` (`reward_funcs`, `num_generations`)

Comprueba el modelo vigente y la versión de TRL.

Alinear sin medir es una opinión.