AI9 · Multimodal

Facturas en imagen y agentes de voz, medidos

AI Surfer · N3-AI Engineering

Qué piden las ofertas (oct. 2026)

- LLM por API + **voz** (transcripción, voces sintéticas)
- **Visión** de documentos
- Integraciones con terceros y **trato con el cliente**
- Perfiles *Forward Deployed* y *AI/ML Engineer* junior

Al terminar: un extractor evaluado y un diseño de agente de voz medido.

Mapa del módulo

Bloque	Pieza de portafolio
Visión-lenguaje	Extractor de facturas con evaluación campo a campo
Voz	Presupuesto de latencia, turnos, interrupciones
Riesgos	Redacción de datos personales, contenido hostil

El modelo es **una pieza**: el trabajo está alrededor.

Imagen → objeto validado

```
client.messages.parse(
    model=MODELO, max_tokens=4000,
    messages=[{"role": "user", "content": [
        {"type": "image", "source": {...}},
        {"type": "text", "text": "Extrae los datos…"}]}],
    output_format=Factura)
```

Forma ≠ verdad: Pydantic valida tipos, no importes.

La revisión determinista

- Suma de líneas = base imponible
- Base + IVA = total
- Formato de CIF, número de factura; fecha válida
- Si algo falla → **revisión humana**

La aritmética no se equivoca.

OCR + reglas vs VLM

	OCR + reglas	VLM
Coste	Muy bajo	Mayor
Formatos nuevos	Reglas nuevas	Suele generalizar
Privacidad	Local	Sale a un proveedor

Estrategia: reglas → VLM si falla → persona si dudas.

Evaluar campo a campo

- Exactitud por campo y **por calidad de imagen**
- Matriz error / aviso:

	Con aviso	**Sin aviso**
Error	bien	**silencioso**
Correcto	falsa alarma	bien

8 documentos = una factura mueve 12 puntos.

Voz

El pipeline y su presupuesto

```
usuario → endpointing → STT → LLM → TTS → agente
```

Objetivo orientativo: **~1 s** hasta el primer sonido.

Etapa	Depende de
Silencio	Tu umbral
LLM 1.er token	Modelo y contexto
TTS 1.er audio	Proveedor

Streaming por frases

- El TTS empieza con la **primera frase**
- No acelera etapas: las **solapa**
- Mira el **p95**, no la mediana

En el notebook: de ~2,8 s en serie a ~1,2 s por frases.

Turnos: no hay umbral perfecto

Silencio	Frases cortadas	Espera añadida
200 ms	4/5	200 ms
1000 ms	0/5	1000 ms

Soluciones: criterio **adaptativo**, STT en streaming, modelos de fin de turno.

Interrupciones (*barge-in*)

1. Una tos **no** es interrupción (voz sostenida ≥ ~300 ms)
2. Callar rápido y **vaciar el búfer**
3. Historial: **solo lo que se llegó a decir**
4. Cancelar lo que LLM/TTS seguían generando

STT: WER no basta

- «pedido 1042» → «pedido 1402»: **WER 0,11** y llamada rota
- Mide **entidades** (números, nombres, importes)
- Confirma los datos críticos a viva voz

Riesgos

- **Datos personales:** minimiza, consentimiento, redacta antes de registrar, retención
- La **voz** es dato personal (y puede ser biométrico)
- **Suplantación:** la voz no prueba identidad
- **Inyección por contenido:** el modelo extrae; **tu código decide**

Resumen

Imagen → objeto validado → revisión → evaluación

Voz → presupuesto → turnos → interrupciones → privacidad

Siguiente: FS1 · full-stack, y el caso práctico con README para un cliente.