Módulo DS5 · Redes y grafos

Ciencia de Datos e IA Aplicada: de los datos a las decisiones

N3-DS · Data Science avanzada · Caso: el club de kárate de Zachary

Qué vas a aprender

#	Lección
7.1	Datos como redes: ejemplos en negocio
7.2	Grafos: nodos, aristas, grados, caminos, componentes
7.3	Mundos pequeños y redes libres de escala
7.4	Centralidades: grado, intermediación, cercanía, autovector
7.5	PageRank
7.6	Comunidades: modularidad, Louvain y clustering espectral
7.7	Predicción de enlaces y difusión en redes

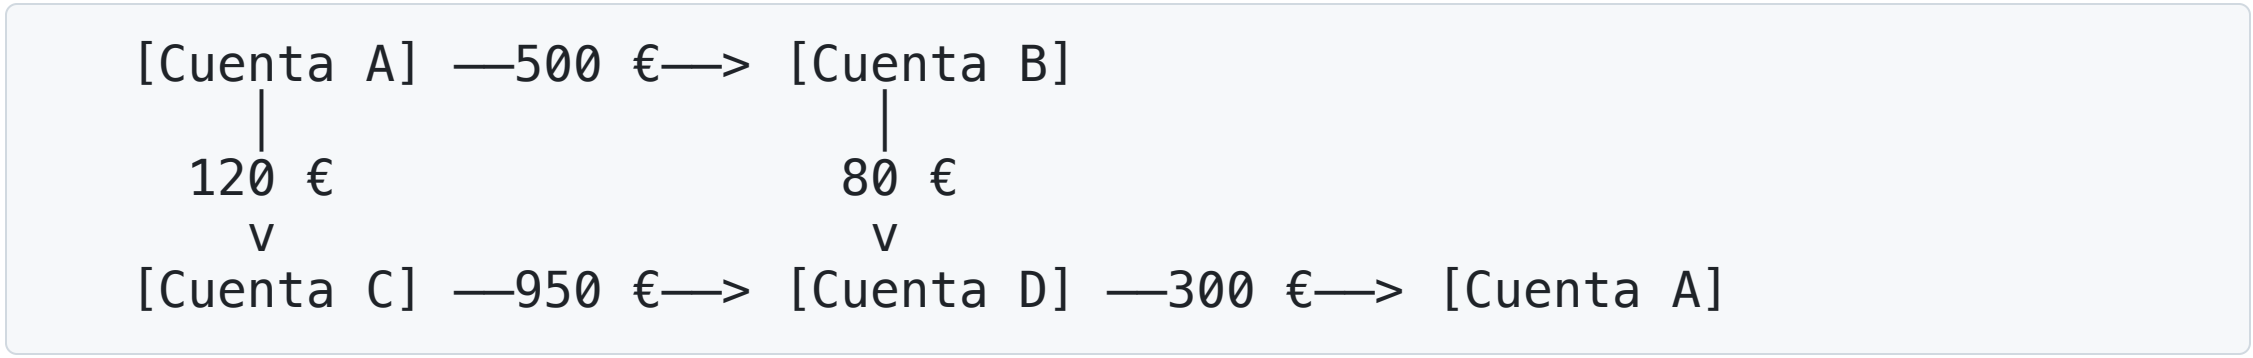
7.1 Datos como redes

Ejemplos en negocio: fraude, logística, redes sociales

Lo que una tabla no ve

- Una fila = una transacción: importe, hora, origen, destino
- Un clasificador aprende «madrugada + importe redondo = sospechoso»
- Pero no ve:
  - 10 cuentas nuevas que se pasan dinero **en círculo**
  - una cuenta «mula» que recibe de 50 y envía a 1
- Esos patrones viven en las **conexiones**

Nodos y aristas



- **Nodos**: entidades (clientes, cuentas, almacenes, páginas)
- **Aristas**: relaciones (pagos, rutas, enlaces, amistades)

Las mismas técnicas, muchos negocios

Dominio	Nodos	Aristas	Pregunta
Fraude	cuentas, dispositivos	transferencias	¿anillos?
Logística	plantas, almacenes	rutas	¿punto único de fallo?
Marketing	usuarios	seguir, recomendar	¿a quién siembro?
Telco	clientes	llamadas	¿riesgo de baja?
Web	páginas	enlaces	¿qué es relevante?
RR. HH.	empleados	correos	¿quién conecta áreas?

Tipos de redes

Dimensión	Opciones	Ejemplo
Sentido	no dirigida / dirigida	amistad / pago
Peso	sin peso / ponderada	conoce / nº de llamadas
Tipos de nodo	uni- / bipartita	personas / clientes-productos
Tiempo	estática / temporal	foto / aristas con fecha

De la tabla al grafo

```
import networkx as nx
G = nx.from_pandas_edgelist(
    transferencias, "origen", "destino",
    edge_attr="importe", create_using=nx.DiGraph)
```

- Casi siempre partes de una **lista de aristas**
- La decisión clave: **qué es un nodo y qué es una arista**
- Escribe la pregunta de negocio **antes** de construir la red

El caso del módulo: club de kárate

- Zachary observa 34 miembros durante 2 años
- Conflicto: instructor (**nodo 0**) vs. presidente (**nodo 33**)
- El club se parte en dos facciones
- Pregunta: **¿podríamos haberlo anticipado solo con la red de amistades?**

7.2 Grafos

Nodos, aristas, grados, caminos, componentes

Tres formas de guardar un grafo

Representación	Aspecto	Cuándo
Lista de aristas	`(0,1), (0,2), ...`	bases de datos
Lista de adyacencia	`0: [1, 2, 3...]`	NetworkX (`G[0]`)
Matriz de adyacencia A	$A_{ij} = 1$ si hay arista	álgebra lineal

Las redes reales son **dispersas**: casi todo A son ceros

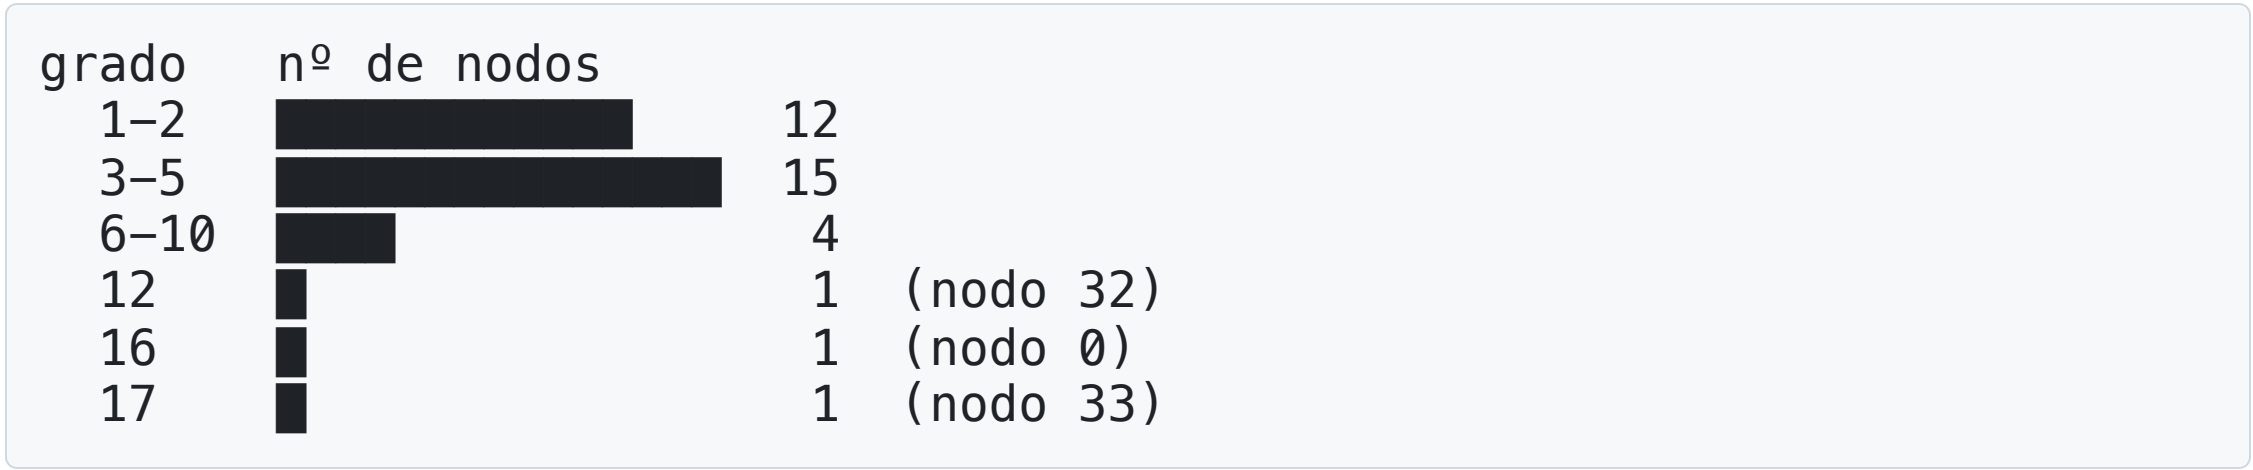
Grado y densidad

- Grado: $k_i = \sum_j A_{ij}$ (entrada y salida si es dirigida)
- Grado medio: $\langle k \rangle = 2m/n$
- Densidad: fracción de aristas posibles que existen

$$\text{densidad} = \frac{m}{n(n-1)/2}$$

- Kárate: $n = 34$, $m = 78$, $\langle k \rangle \approx 4{,}59$, densidad $\approx 0{,}14$

Distribución de grados



- La primera gráfica que debes mirar
- Dos nodos destacan: ya intuyes quiénes son los líderes

Caminos y distancias

- **Distancia** $d(i, j)$: aristas del camino más corto
- **Distancia media**: kárate $\approx 2{,}41$
- **Diámetro**: la mayor distancia; kárate = 5
  - 16 → 5 → 0 → 31 → 25
- Cálculo: BFS (sin pesos) o Dijkstra (con costes)
- Ojo: si el peso es «intensidad», la distancia sería $1/w$

Componentes conexas

- **Conexa**: hay camino entre cualquier par
- Si no: varias **componentes**; casi siempre hay una **gigante**
- Dirigidas: débil vs. **fuertemente** conexa
- Fraude: componente fuertemente conexa de cuentas nuevas = dinero en círculo

Agrupamiento: los amigos de mis amigos

$$C_i = \frac{\text{aristas entre los vecinos de } i}{k_i(k_i - 1)/2}$$

	Agrupamiento medio
Club de kárate	**0,57**
Red aleatoria equivalente	0,14

Muchos triángulos = grupos cohesionados

Las métricas en el notebook

```
nx.density(G)                          # 0.139
nx.average_shortest_path_length(G)     # 2.41
nx.average_clustering(G)               # 0.57
nx.number_connected_components(G)      # 1
```

Notebook, sección 1 · Métricas básicas

Errores frecuentes

- Distancia media en red **no conexa** → error (distancia infinita)
  - usa la componente gigante o la **eficiencia global**
- Comparar densidades de redes de tamaños distintos
- Confundir agrupamiento medio (0,57) con transitividad (0,26)

7.3 Mundos pequeños y redes libres de escala

Dos sorpresas de las redes reales

1. **Mundo pequeño**: todos están a pocos saltos de todos
2. **Libre de escala**: unos pocos *hubs* acaparan conexiones

Consecuencias: velocidad de difusión, robustez, valor de los *hubs*

Referencia: la red aleatoria (Erdős–Rényi)

- Cada par se une con la misma probabilidad p
- Grados ≈ Poisson: todos parecidos, **sin hubs**
- Distancias cortas: $\ell \sim \ln n / \ln \langle k \rangle$
- Agrupamiento minúsculo: $C \approx p$

Seis grados de separación

- Milgram (1967): cartas de Nebraska y Kansas a Boston
- Solo vía conocidos personales
- Las que llegaron: **≈ 6 pasos** de media
- Lo sorprendente: distancias cortas **y** muchos triángulos a la vez

Watts–Strogatz: unos pocos atajos

Anillo de 1.000 nodos, 10 vecinos cada uno, recableamos una fracción p

p	**Agrupamiento**	**Distancia media**
0	0,67	50,5
0,01	0,65	**9,6**
0,1	0,49	4,4
1	0,01	3,3

Con un 1 % de atajos: distancia ÷ 5, agrupamiento casi igual

¿Es el kárate un mundo pequeño?

	Kárate	**Aleatoria (34 nodos, 78 aristas)**
Distancia media	2,41	2,42
Agrupamiento	**0,57**	0,14

Mismas distancias, **4 veces más triángulos** → sí

Redes libres de escala

$$P(k) \propto k^{-\gamma}, \qquad 2 < \gamma < 3$$

- En log-log: casi una recta de pendiente $-\gamma$
- Existen **hubs** con grado cientos de veces la media

10.000 nodos, grado medio 4	**Grado máximo**
Aleatoria	14
Barabási–Albert	≈ 260

¿De dónde salen los hubs?

Modelo de **Barabási–Albert**:

1. **Crecimiento**: llegan nodos nuevos
2. **Enlace preferencial**: se conectan más a quien ya tiene más

«El rico se hace más rico»: webs, aeropuertos, influencers

Ojo: ajustar una ley de potencias es delicado: lo que importa es **si hay hubs**

Consecuencias para el negocio

- **Difusión rápida**: siembra en un *hub* y llegas antes
- **Robusta a fallos aleatorios, frágil ante ataques** a los *hubs*
- **Paradoja de la amistad**: tus amigos tienen más amigos que tú
    - kárate: grado medio 4,6 vs. grado medio de «un amigo» 7,8

Ejercicio 2 del notebook: quitar un nodo

7.4 Centralidades

Grado, intermediación, cercanía, autovector

«Importante» depende de la pregunta

Pregunta	Medida
¿Quién tiene más contactos?	Grado
¿Quién conecta grupos?	Intermediación
¿Quién llega rápido a todos?	Cercanía
¿Quién está rodeado de importantes?	Autovector

Centralidad de grado

$$C_D(i) = \frac{k_i}{n-1}$$

- Popularidad, exposición directa
- Kárate: 33 → 0,515 · 0 → 0,485
- Barata, útil, pero **solo mira el vecindario inmediato**

Centralidad de intermediación

$$C_B(i) = \sum_{s \neq i \neq t} \frac{\sigma_{st}(i)}{\sigma_{st}}$$

- Fracción de caminos más cortos que pasan por i
- **Puentes y cuellos de botella**
- Kárate: el instructor (0) lidera con 0,438
- Pregunta: «¿qué pasa si este nodo desaparece?»

Centralidad de cercanía

$$C_C(i) = \frac{n-1}{\sum_{j \neq i} d(i,j)}$$

- Inversa de la distancia media al resto
- Llegar rápido a todos: ubicación, difusión urgente
- En redes pequeñas los valores están muy apretados (0,50–0,57)

Centralidad de autovector

$$x_i = \frac{1}{\lambda} \sum_j A_{ij} x_j \iff A\mathbf{x} = \lambda \mathbf{x}$$

- **Eres importante si tus vecinos lo son**
- Autovector del mayor autovalor (Perron–Frobenius)
- Kárate: 33 (0,373) supera al 0 (0,355)
- Problema en dirigidas: sin enlaces de entrada → 0 → lo arregla PageRank

Comparación en el club

Nodo	Grado	Interm.	Cercanía	Autovector
0	0,485	**0,438**	**0,569**	0,355
33	**0,515**	0,304	0,550	**0,373**
32	0,364	0,145	0,516	0,309
2	0,303	0,144	0,559	0,317
31	0,182	0,138	0,541	0,191

Coinciden arriba, discrepan en medio · Spearman interm.–autovector: 0,69

En el notebook

```
centralidades = pd.DataFrame({
    "grado": nx.degree_centrality(G),
    "intermediación": nx.betweenness_centrality(G),
    "cercanía": nx.closeness_centrality(G),
    "autovector": nx.eigenvector_centrality(G),
    "pagerank": nx.pagerank(G),
})
```

Notebook, sección 2 · Ejercicio 4: *Los miserables*

Ejemplo: retención de talento

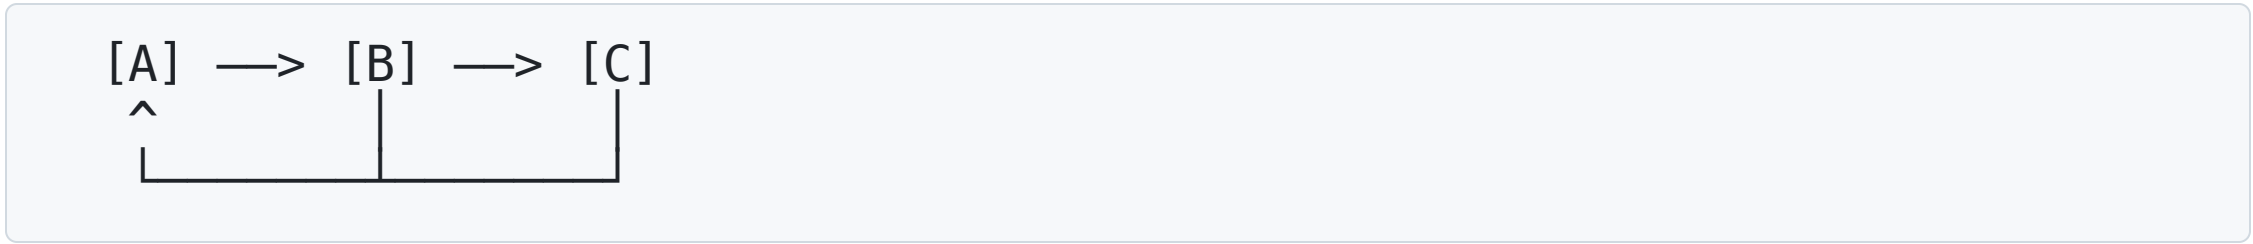
- Red de correos y reuniones de 2.000 empleados
- **Grado**: directivos y asistentes de dirección
- **Intermediación**: un técnico de sistemas y una responsable de compras
  - únicos enlaces entre sede y dos fábricas
- El plan de sucesión debe mirar la **intermediación**

7.5 PageRank

El problema de Google (finales de los 90)

- Ordenar por nº de veces que aparece la palabra → fácil de manipular
- Idea de Page y Brin: **una página es relevante si la enlazan páginas relevantes**
- Centralidad de autovector + red dirigida enorme + problemas prácticos

El paseante aleatorio



- Empieza en una página, hace clic en un enlace al azar, repite
- Tras muchísimos pasos: ¿qué fracción del tiempo pasa en cada página?
- **Esa fracción es el PageRank**

Cadena de Markov

$$M_{ij} = \frac{A_{ji}}{k_j^{\text{out}}} \qquad \mathbf{r}^{(t+1)} = M\mathbf{r}^{(t)}$$

- M: probabilidad de pasar de j a i (columnas suman 1)
- Buscamos la **distribución estacionaria**: $\mathbf{r} = M\mathbf{r}$

Dos problemas

Problema	Qué pasa
Callejón sin salida	página sin enlaces de salida: la probabilidad «se escapa»
Trampa	grupo que solo se enlaza entre sí: absorbe todo el PageRank

La solución: teletransporte

$$\mathbf{r} = \frac{1-d}{n}\mathbf{1} + d\,M\mathbf{r}$$

- Con prob. d (≈ 0,85) sigue un enlace; con $1-d$ salta a cualquier nodo
- Garantiza una **solución única** desde cualquier inicio
- $d = 0{,}85$ → sigue unos $1/(1-d) \approx 6{,}7$ enlaces antes de saltar

Iteración de potencias

```
def pagerank(G, d=0.85, iters=100):
    A = nx.to_numpy_array(G, nodelist=sorted(G))
    M = A / A.sum(axis=0, keepdims=True)
    n = len(A)
    r = np.full(n, 1 / n)
    for _ in range(iters):
        r = (1 - d) / n + d * M @ r
    return r
```

Sin invertir matrices · Diferencia con `nx.pagerank` $\approx 10^{-5}$

PageRank en el kárate

Nodo	PageRank	Grado
33	0,097	17
0	0,089	16
32	0,076	12
2	0,063	10

- En no dirigidas, muy parecido al grado
- Brilla en **redes dirigidas**: importa *quién* te enlaza

PageRank personalizado

- El teletransporte solo va a un **conjunto de nodos de interés**
- Mide **proximidad** a ese conjunto
- Recomendación: cercano a lo que compró el cliente
- Fraude: teletransporte a las 300 cuentas confirmadas → revisa las de mayor puntuación

```
nx.pagerank(G, personalization={nodo: 1 for nodo in fraudes})
```

7.6 Comunidades

Modularidad, Louvain y clustering espectral

¿Qué es una comunidad?

- Grupo con **muchas aristas dentro y pocas fuera**
- Como el clustering del módulo 02, pero **sin coordenadas**
- Negocio: anillos de fraude, grupos de clientes, equipos informales
- Kárate: conocemos la verdad (las dos facciones)

Modularidad

$$Q = \frac{1}{2m} \sum_{i,j} \left[A_{ij} - \frac{k_i k_j}{2m} \right] \delta(c_i, c_j)$$

- Aristas internas **menos** las esperadas al azar con los mismos grados
- $Q \approx 0$: nada especial · $Q > 0{,}3$: estructura clara
- Kárate, partición real: $Q = 0{,}39$

Louvain en dos fases

1. **Movimiento local**: cada nodo se mueve a la comunidad vecina que más sube Q
2. **Agregación**: cada comunidad → supernodo; repetir

- Rápido: millones de nodos
- **Elige solo el nº de comunidades**
- Aleatorio → fija `seed` · Sucesor: Leiden

Louvain en el kárate

```
comunidades = community.louvain_communities(G, seed=0)
community.modularity(G, comunidades)   # 0.444
```

- **4 comunidades**, $Q = 0{,}444$ (> 0,39 de la partición real)
- ARI vs. facciones reales = 0,51
- No se equivoca: **subdivide** cada facción

La matriz laplaciana

$$L = D - A \qquad \mathbf{x}^\top L\mathbf{x} = \sum_{(i,j)\in E} (x_i - x_j)^2$$

- Autovalores ≥ 0; nº de ceros = nº de componentes
- λ_2 pequeño → fácil partir la red en dos
- **Vector de Fiedler** (autovector de λ_2): corte mínimo equilibrado relajado

Clustering espectral en 4 líneas

```
L = nx.laplacian_matrix(G, nodelist=sorted(G)).toarray().astype(float)
autovalores, autovectores = np.linalg.eigh(L)
fiedler = autovectores[:, 1]
etiqueta_espectral = (fiedler > 0).astype(int)
```

- **El signo** del vector de Fiedler asigna cada nodo a un lado

Resultado: se anticipa la ruptura

Método	Grupos	ARI vs. real	Aciertos
Louvain	4	0,51	(subgrupos)
Espectral	2	**0,88**	**33 de 34**

- Solo falla el nodo 8, con amigos en ambos bandos
- Más de 2 grupos: k autovectores + k-means

¿Louvain o espectral?

	Louvain	Espectral
N° de grupos	lo decide	lo fijas (k)
Escala	millones	miles
Base	máx. modularidad	corte mínimo
Ideal si	exploras	sabes cuántos grupos

Errores frecuentes

- Tomar la modularidad máxima como «la verdad» (límite de resolución)
- Comparar etiquetas directamente → usa **ARI**
- Olvidar la `seed` en Louvain
- Actuar sin describir la comunidad con datos: es una **hipótesis**

7.7 Predicción de enlaces y difusión

Dos preguntas dinámicas

1. **Predicción de enlaces**: ¿qué conexiones aparecerán (o existen sin verse)?
    - «personas que quizá conozcas», relaciones ocultas
2. **Difusión**: si algo empieza en unos pocos nodos, ¿hasta dónde llega?
    - campañas, rumores, contagio financiero

Heurísticas de vecindad

Heurística	Fórmula
Vecinos comunes	$\lvert\Gamma(u) \cap \Gamma(v)\rvert$
Jaccard	$\dfrac{\lvert\Gamma(u) \cap \Gamma(v)\rvert}{\lvert\Gamma(u) \cup \Gamma(v)\rvert}$
Adamic-Adar	$\displaystyle\sum_{w \in \Gamma(u) \cap \Gamma(v)} \frac{1}{\log k_w}$
Enlace preferencial	$k_u \cdot k_v$

Intuición: **cierre triádico**

Adamic-Adar: no todos los amigos comunes valen igual

```
Ana ── Pepe (3 contactos) ── Luis     → peso 1/log 3 ≈ 0,91
Ana ── Influencer (5.000) ── Luis     → peso 1/log 5000 ≈ 0,12
```

- Compartir a alguien que conoce a todo el mundo informa poco
- Compartir a alguien con pocos contactos sugiere vínculo estrecho

Evaluar: ocultar aristas

1. Ocultar el 10 % de las aristas
2. Puntuar los pares no conectados en la red restante
3. ¿Cuántas ocultas aparecen en el top-k?

Es la separación entrenamiento / prueba aplicada a redes

Resultado en el notebook

	Valor
Aristas ocultas	7
Pares no conectados	490
Recuperadas por Adamic-Adar (top-7)	**1**
Esperado al azar	0,1

- 10 veces mejor que el azar, pero **muy ruidoso** → repite con semillas, usa AUC

Modelos de difusión

Modelo	Regla
SI / SIR	cada informado contagia a cada vecino con prob. p en cada ronda
Cascada independiente	cada nodo recién activado tiene **una** oportunidad por vecino

- Se simulan **muchas veces** (Monte Carlo) y se promedia

Elegir semillas: ejercicio 1

Semillas	5 rondas	2 rondas
Centrales (0, 33, 32)	≈ 97 %	≈ 70 %
3 al azar	≈ 89 %	≈ 40 %

- Elegir bien importa más cuanto **menos tiempo** tiene el mensaje
- Añade **diversidad**: semillas en comunidades distintas
- Óptimo aproximado: algoritmo voraz (≥ 63 % del óptimo)

Hubs: viralizar o frenar

- En redes con *hubs*, el umbral de epidemia es muy bajo
- Para **viralizar**: siembra en *hubs* de comunidades distintas
- Para **frenar** (bulos, contagio financiero): protege a los *hubs* primero
- Simula para **comparar estrategias**; para predecir cifras, calibra p con datos

Resumen del módulo

Redes → métricas → centralidad → PageRank → comunidades → enlaces y difusión

Entregable: estrategia de difusión o análisis de robustez (máx. 2 páginas)