Módulo 01

Estadística para la toma de decisiones

¿Cuánto me puedo fiar de lo que veo en una muestra?

Semana 2 · Ciencia de Datos e IA Aplicada

1.1

Población, muestra y por qué la incertidumbre importa en los negocios

La pregunta del director comercial

> «¿Cuál es el importe medio de un pedido?»

- Tenemos **200 pedidos**: media = **28,08 €**
- Otro analista, otros 200 pedidos → otra cifra
- Nadie ha calculado mal: **cada muestra cuenta una versión distinta**
- La pregunta útil: **¿cuánto es y cuánto podemos fiarnos?**

Población y muestra

	Describe...	Notación	En el caso
Parámetro	la población (fijo, desconocido)	$\mu,\ \sigma,\ p$	media real: 27,79 €
Estadístico	la muestra (varía)	$\bar{x},\ s,\ \hat{p}$	media de 200: 28,08 €

Inferencia = usar estadísticos para decir algo **responsable** sobre parámetros

¿Por qué no medirlo todo?

- **Coste y tiempo**: encuestas, auditorías, inspecciones
- **Destrucción**: pruebas que rompen el producto
- **El futuro**: los datos de 2025 son una muestra del proceso de 2026
- **Experimentos**: el 10 % que ve la nueva interfaz es una muestra

Dos errores muy distintos

	Error aleatorio	Sesgo
Origen	azar del muestreo	muestra no representativa
¿Baja con más datos?	**Sí** ($\propto 1/\sqrt{n}$)	**No**
¿Se puede cuantificar?	Sí: EE, IC	Difícil
Defensa	más n	**muestreo aleatorio**

Un millón de pedidos de viernes noche siguen siendo de viernes noche

La incertidumbre es dinero

- **Pedido mínimo** fijado con un ticket medio mal estimado
- **Campaña «ganadora»** por 0,3 puntos en una muestra pequeña
- **Flota** dimensionada con la media, sin mirar la variabilidad

Regla del curso: **toda estimación va con su margen de error**

Ideas clave 1.1

- Población (lo que interesa) ≠ muestra (lo que ves)
- Parámetros fijos y desconocidos; estadísticos variables
- Más datos reducen el error aleatorio, **no el sesgo**
- Aleatorizar es la mejor defensa contra el sesgo

Practica: Notebook, sección 2

1.2

Variables aleatorias y distribuciones

Variable aleatoria

Un número asociado a un resultado incierto

- Importe del próximo pedido → **continua** (densidad)
- Pedidos entre 21:00 y 22:00 → **discreta** (probabilidad)
- ¿Compra? 1/0 → **Bernoulli**

Resúmenes: media $E[X] = \mu$, varianza σ^2, desviación típica σ

Binomial: éxitos en n intentos

$$P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}$$

$$E[X] = np \qquad \mathrm{Var}(X) = np(1-p)$$

- Conversiones de una campaña, clics, abandonos
- 20 envíos, $p = 0{,}1$ → esperamos 2; $P(0) \approx 0{,}12$
- Supone intentos **independientes** con la misma p

Poisson: conteos por intervalo

$$P(X = k) = \frac{\lambda^k e^{-\lambda}}{k!} \qquad E[X] = \mathrm{Var}(X) = \lambda$$

- Pedidos por hora, incidencias por día
- Rasgo: **media = varianza**
- Varianza ≫ media → sobredispersión (picos, festivos, grupos)

Normal: sumas y medias

- Parámetros μ y σ; simétrica
- Regla 68 – 95 – 99,7 % a 1, 2 y 3 σ
- Aparece al sumar muchos efectos pequeños
- Sobre todo: **distribución de las medias muestrales** (TCL)

Ojo: Importes, tiempos y conteos casi nunca son normales

Exponencial: tiempos de espera

- Minutos hasta el siguiente pedido
- Ritmo λ de Poisson → espera media $1/\lambda$
- Muy asimétrica: muchas esperas cortas, pocas largas
- **Sin memoria**: lo que falta no depende de lo ya esperado

Log-normal: cantidades positivas asimétricas

- $\log X$ es normal; efectos que se **multiplican**
- Importes, salarios, duración de sesiones
- Cola derecha → **media > mediana**

`lognormal(3.2, 0.5)`	Valor
Mediana $e^{3{,}2}$	≈ 24,5 €
Media $e^{3{,}2+0{,}5^2/2}$	≈ 27,8 €

En Python: `scipy.stats`

```
from scipy import stats
stats.binom(n=20, p=0.1).pmf(0)    # ≈ 0,12
stats.poisson(mu=4).sf(7)          # P(>7 pedidos/h) ≈ 0,05
stats.expon(scale=5).cdf(2)        # P(espera < 2 min) ≈ 0,33
```

- «¿Qué probabilidad hay de…?» → `cdf` / `sf`
- «¿Qué valor no se supera el 95 %?» → `ppf`

¿Qué distribución elijo?

Variable	Modelo de partida
Éxitos / fracasos	Binomial
Conteo por intervalo	Poisson
Tiempo de espera	Exponencial
Cantidad positiva asimétrica	Log-normal
Media de muchas observaciones	Normal

Después: **comprueba** con histograma y gráfico Q-Q

Practica: Notebook, sección 1

1.3

Ley de los grandes números y teorema central del límite

Ley de los grandes números

$$\bar{x}_n = \frac{1}{n}\sum_{i=1}^{n} x_i \longrightarrow \mu \quad (n \to \infty)$$

- 10 pedidos: la media salta
- 1 000 pedidos: oscila poco
- 5 000 pedidos: pegada a 27,79 €

Lo individual es incierto; lo agregado es estable

Lo que la LGN NO dice

- **No:** «Tres días malos → le toca uno bueno» (**falacia del jugador**)
- La LGN habla del largo plazo, no de compensaciones
- Dice *que* converge, no *a qué velocidad*

→ La velocidad la da el **TCL**

Teorema central del límite

Si las observaciones son independientes con varianza finita σ^2:

$$\bar{x} \approx \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$$

Sea cual sea la forma de la distribución original

Desviación típica de $\bar{x}$ = $\sigma/\sqrt{n}$ = **error estándar**

El TCL en el notebook

n	Forma de $\bar{x}$	EE $= \sigma/\sqrt{n}$
2	aún asimétrica	≈ 10,5 €
10	casi simétrica	≈ 4,7 €
100	prácticamente normal	≈ 1,5 €

$\sigma \approx 14{,}8$ € (pedidos log-normales)

Intuición y consecuencia

- Al promediar, grandes y pequeños se **compensan**
- Una media extrema exige muchos extremos **a la vez**
- El error baja con $\sqrt{n}$, no con n

$$\text{error}/2 \;\Rightarrow\; n \times 4$$

Límites del TCL

- «n suficiente» depende de la **asimetría** ($n \geq 30$ es orientativo)
- Necesita **independencia** (ojo: varios pedidos por cliente, series)
- Colas extremadamente pesadas → cuidado
- Habla de la **media**, no de los datos individuales

Ejemplo: alarma en una tienda

Gasto por cliente: $\mu = 42$ €, $\sigma = 30$ €, 400 clientes/día

$$EE = \frac{30}{\sqrt{400}} = 1{,}5 \text{ €}$$

¿Media del día < 39 €? Está a **2 EE** → probabilidad ≈ 2,3 %

→ Si ocurre, merece la pena investigar

Practica: Notebook, secciones 3 y 4

1.4

Estimación y error estándar

Estimador y estimación

- **Estimador**: la regla → «suma y divide entre n»
- **Estimación**: el número → 28,08 €
- Sesgo y precisión son propiedades **del estimador**

Propiedades deseables

Propiedad	Significado
Insesgado	en promedio acierta: $E[\hat{\theta}] = \theta$
Preciso	poca variación entre muestras
Consistente	se concentra en θ al crecer n

Diana: agrupado pero desviado = preciso y **sesgado**

¿Por qué $n-1$?

$$s = \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2}$$

- Las desviaciones se miden respecto a $\bar{x}$, ajustada a los datos
- Dividir entre n **subestima** la varianza
- NumPy: `x.std(ddof=1)` · pandas: `ddof=1` por defecto

Desviación típica vs. error estándar

	Desviación típica s	Error estándar $s/\sqrt{n}$
Mide	variación de **los pedidos**	variación de **la media**
Si n crece	se estabiliza ($\approx \sigma$)	**baja** como $1/\sqrt{n}$
Pregunta	¿cómo de distintos son?	¿cuánto me fío de la media?
Caso $n = 200$	**16,12 €**	**1,14 €**

Con más datos...

n	s	EE
200	≈ 16 €	≈ 1,14 €
20 000	≈ 15–16 €	≈ 0,11 €

Los clientes no se vuelven más parecidos por observarlos más

```
s  = muestra.std(ddof=1)
ee = stats.sem(muestra)   # = s / sqrt(n)
```

Error estándar de otras estimaciones

Estimación	EE
Media	$s/\sqrt{n}$
Proporción	$\sqrt{\hat{p}(1-\hat{p})/n}$
Diferencia de medias	$\sqrt{s_1^2/n_1 + s_2^2/n_2}$
Mediana, percentiles, ratios	→ **bootstrap** (1.6)

Ej.: 1 000 visitas, 5 % conversión → EE ≈ 0,69 puntos

Errores frecuentes

- Describir a los clientes con el EE («28 ± 1 €»)
- Barras de error **sin etiqueta**
- Elegir el EE «porque queda más preciso»
- Ignorar la dependencia (varios pedidos por cliente)

Practica: Notebook, secciones 4 y 5

1.5

Intervalos de confianza: construcción e interpretación

De un punto a un intervalo

- Estimación puntual: 28,08 € → casi seguro no es exacta
- Por el TCL, en el 95 % de las muestras $\left|\bar{x} - \mu\right| < 1{,}96 \cdot EE$
- Le damos la vuelta:

$$\bar{x} \pm 1{,}96 \cdot EE \ \text{ contiene a } \mu \text{ en el } 95\,\% \text{ de las muestras}$$

La fórmula con t de Student

$$\bar{x} \pm t_{0.975,\, n-1} \cdot \frac{s}{\sqrt{n}}$$

- t compensa que estimamos σ con s
- $n = 200$: $t \approx 1{,}97$ · $n = 10$: $t \approx 2{,}26$
- $t \cdot EE$ = **margen de error**

```
stats.t.interval(0.95, df=n-1, loc=media, scale=ee)
```

Nuestro intervalo

Media: 28,08 € · IC 95 %: [25,84 €; 30,33 €]

- Margen de error ≈ ±2,25 €
- Media real (solo la sabemos porque simulamos): 27,79 € (dentro del IC)
- Proporción: $\hat{p} \pm 1{,}96\sqrt{\hat{p}(1-\hat{p})/n}$

¿Qué significa «95 %»?

> Si repitiéramos el muestreo muchas veces, **el 95 % de los intervalos** construidos así contendrían la media real

- El 95 % es del **método**, no de un intervalo concreto
- Un intervalo ya calculado **contiene o no** a μ
- Por eso decimos «confianza», no «probabilidad»

Interpretaciones incorrectas

- **No:** «El 95 % de los pedidos cuesta entre 25,84 y 30,33 €»
  → el IC es para la **media**, no para pedidos
- **No:** «El 95 % de nuevas medias caerá en este intervalo»
- **No:** «La media real cambia y está dentro el 95 % del tiempo»
- **No:** «Al 99 % es siempre mejor» → es más **ancho**

Comprobación: cobertura

100 muestras de 200 pedidos → 100 intervalos

96 de 100 contienen la media real

- Esperable: ≈ 95 ± 4 por azar
- Los que fallan no tienen nada raro: es el 5 % asumido

Practica: Notebook, sección 5 (gráfico de intervalos)

Qué controla la anchura

$$\text{semianchura} = t \cdot \frac{s}{\sqrt{n}}$$

Palanca	Efecto
Confianza 90 / 95 / 99 %	z = 1,645 / 1,96 / 2,576
Más variabilidad s	más ancho
$n \times 4$	anchura / 2

Tamaño de muestra: $n \approx \left(\frac{1{,}96\, s}{E}\right)^2$

Cómo comunicarlo

> «Estimamos que el ticket medio está entre 25,8 € y 30,3 €, con un método que acierta en 95 de cada 100 ocasiones.»

- Supuestos: muestra aleatoria, independencia, n suficiente
- IC solapados **no** prueban «sin diferencia» → IC de la diferencia (mód. 04)

Practica: Ejercicios 1 y 3

1.6

Bootstrap: incertidumbre para cualquier métrica

El problema

Métricas sin fórmula sencilla de EE:

- **Mediana** del importe (pedido típico)
- **Percentil 90** del tiempo de entrega
- **Ratios**: ingresos por usuario activo
- Diferencia de medianas entre versiones

¿Renunciamos a dar incertidumbre? **No**

La idea

- Solo tenemos **una** muestra
- Si es aleatoria y suficiente, **se parece a la población**
- → Usamos la muestra **como si fuera la población**
- Simulamos el muestreo remuestreando de ella

El algoritmo

1. Muestra original de tamaño n
2. Elige n observaciones **con reemplazo**
3. Calcula el estadístico
4. Repite B veces (p. ej., 5 000)
5. Distribución bootstrap →
    - **EE** = su desviación típica
    - **IC 95 %** = percentiles 2,5 y 97,5

En Python

```
def bootstrap(datos, estadistico, n_boot=5_000, rng=rng):
    idx = rng.integers(0, len(datos), (n_boot, len(datos)))
    return np.array([estadistico(datos[i]) for i in idx])

boot_mediana = bootstrap(muestra, np.median)
lo, hi = np.percentile(boot_mediana, [2.5, 97.5])
```

Alternativa: `scipy.stats.bootstrap(..., method="BCa")`

Resultado: la mediana

	Valor
Mediana muestral	24,50 €
IC 95 % bootstrap	[21,89 €; 27,02 €]
Mediana poblacional	24,53 € (dentro del IC)
Media muestral (comparación)	28,08 €

Datos asimétricos → reporta **media y mediana**

Cuándo sí, cuándo con cuidado

Úsalo	Con cuidado
Mediana, percentiles, ratios	n muy pequeño (< 15–20)
Datos asimétricos	Máximo, mínimo, P99
Validar una fórmula	Series temporales, grupos
Métricas de modelos (AUC…)	Muestra sesgada

Ideas clave 1.6

- Remuestrear **con reemplazo** imita el azar del muestreo
- Sirve para **cualquier** estadístico
- Cuantifica el error aleatorio, **no corrige el sesgo**
- Ejemplo: comprometer un plazo de entrega con el **extremo superior** del IC del P90

Practica: Notebook, sección 5 · Ejercicio 2

1.7

Correlación, causalidad y paradoja de Simpson

Correlación de Pearson

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2}\sqrt{\sum (y_i - \bar{y})^2}} \in [-1, 1]$$

- Mide relación **lineal**: fuerza y sentido
- `df["x"].corr(df["y"])`
- $r \approx 0$ ≠ «no hay relación»

Lo que r no ve

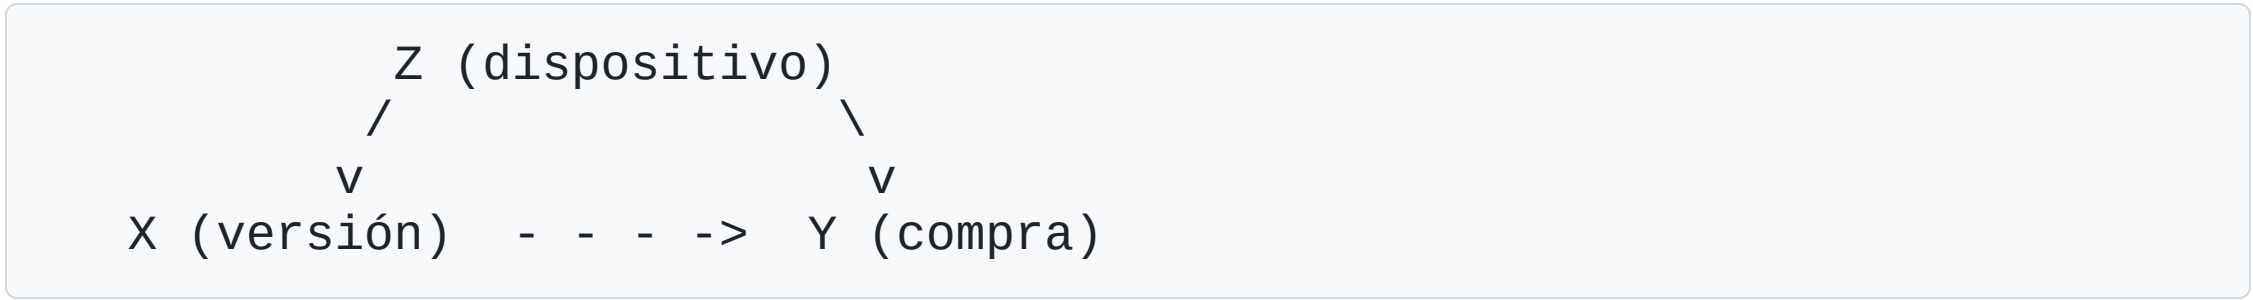
- **No es la pendiente**: r alto con efecto minúsculo
- **No lineal**: una U puede dar $r \approx 0$
- **Atípicos**: un cliente gigante crea o destruye r
- Alternativa robusta: **Spearman** (rangos)

Grafica siempre el diagrama de dispersión

Cinco explicaciones de una correlación

Explicación	Ejemplo
$X \to Y$	lo que queremos creer
$Y \to X$ (inversa)	más ventas → más empleados
$Z \to X$ y $Z \to Y$ (**confusión**)	calor → helados y ahogamientos
Selección	solo clientes que siguen activos
Azar	muchas variables, alguna correlaciona

Variable de confusión



Z influye en **quién recibe** X y en **el resultado** Y

Si no la tienes en cuenta, atribuyes a X el efecto de Z

El test de la app (notebook)

Versión	Móvil	Escritorio	Global
A	**5,0 %** (8 000)	**15,0 %** (2 000)	7,0 %
B	4,0 % (2 000)	13,0 % (8 000)	**11,2 %**

- Global: B gana por 4,2 puntos
- Por segmento: **A gana en los dos** (+1 en móvil, +2 en escritorio)
- B se mostró sobre todo en **escritorio**, donde todos convierten más

Por qué se invierte: medias ponderadas

$$\mathrm{A} = 0{,}8 \cdot 5\,\% + 0{,}2 \cdot 15\,\% = 7{,}0\,\%$$
$$\mathrm{B} = 0{,}2 \cdot 4\,\% + 0{,}8 \cdot 13\,\% = 11{,}2\,\%$$

- Cada tasa global es una **media ponderada** de sus segmentos
- Pesos muy distintos: A 80 % móvil, B 80 % escritorio
- La ventaja de B es **efecto de composición**, no de la versión
- Lanzar B a todos **empeoraría** la conversión en ambos dispositivos

Qué hacer

- **Aleatorizar** la asignación (prueba A/B, módulo 04)
- **Estratificar** o **controlar** confusoras (regresión, módulo 03)
- Pensar la **estructura causal** antes de calcular
- Ojo: no controles por variables **posteriores** al tratamiento

Checklist antes de concluir «causa»

1. ¿Cómo se asignó el «tratamiento»?
2. ¿En qué más se diferencian los grupos?
3. ¿Podría ir al revés la causalidad?
4. ¿Hay filtrado o selección en los datos?
5. ¿La comparación es justa por segmento?

Practica: Notebook, sección 6 · Ejercicio 4

Resumen del módulo

Distribuciones → LGN y TCL → error estándar → IC → bootstrap → causalidad

Caso práctico: ¿cuál es el importe medio y cuánto podemos fiarnos?