Módulo 02

Datos no estructurados: clustering y reducción de dimensión

Ciencia de Datos e IA Aplicada · Semana 3

En este módulo

#	Lección
2.1	Aprendizaje supervisado vs. no supervisado
2.2	Distancias y por qué escalar
2.3	k-means: algoritmo, supuestos y limitaciones
2.4	Elegir *k*: codo, silueta y criterio de negocio
2.5	Clustering jerárquico y dendrogramas
2.6	PCA: intuición geométrica y varianza explicada
2.7	t-SNE y UMAP: visualizar datos de alta dimensión
2.8	Caso: segmentación RFM de clientes

2.1

Aprendizaje supervisado vs. no supervisado

Un problema sin respuestas

- 1.500 clientes de un e-commerce
- Sabemos cuándo compraron, cuánto y cuántas veces
- **No** sabemos «qué tipo de cliente» es cada uno
- Marketing pregunta: *¿qué grupos tenemos y qué hacemos con cada uno?*

No hay columna objetivo que predecir

Dos formas de aprender

	Supervisado	No supervisado
Datos	X y y	Solo X
Pregunta	¿Qué valor tendrá y?	¿Qué estructura hay en X?
Evaluación	Comparar con y real	Criterios internos + utilidad
Ejemplo	¿Se dará de baja?	¿Qué tipos de cliente hay?

Tres tareas no supervisadas

- **Clustering**: grupos de observaciones parecidas
  → segmentar clientes
- **Reducción de dimensión**: muchas variables → pocas
  → resumir 40 preguntas de encuesta en 3 índices
- **Detección de anomalías**: lo que no se parece a nada
  → transacciones sospechosas

¿Por qué es más subjetivo?

- No hay «respuesta correcta» con la que medir exactitud
- El algoritmo **siempre** devuelve grupos, aunque no existan
- Tres filtros para juzgar un resultado:
    i. Criterios internos (compacidad, separación)
    ii. Estabilidad (¿sale lo mismo con otra muestra?)
    iii. Utilidad (¿cambia alguna decisión?)

Cuándo aporta valor

- Explorar antes de modelar
- Segmentar para actuar distinto por grupo
- Comprimir y visualizar
- Crear variables para modelos supervisados
- Etiquetar barato: agrupar y revisar representantes

En el notebook: un lujo didáctico

- Datos simulados con 4 perfiles ocultos: `perfil_real`
- Medimos el acierto con el **ARI** (Adjusted Rand Index)
  - 1 = coincide con los perfiles reales
  - ≈ 0 = como asignar al azar
- En un proyecto real **no tendrás** esa columna

2.2

Distancias y por qué escalar

Parecido = cercanía

Cada cliente es un punto $x = (x_1, \ldots, x_p)$

$$d(x, z) = \sqrt{\sum_{j=1}^{p} (x_j - z_j)^2}$$

- Euclídea: la "línea recta"
- Manhattan: $\sum_j |x_j - z_j|$
- Coseno: compara direcciones (texto)

El problema de las unidades

Variable	Unidad	Desv. típica
recencia	días	≈ 140
frecuencia	compras/año	≈ 9,5
gasto_medio	€	≈ 93

100 días de recencia pesan igual que 100 compras al año

→ la frecuencia casi no cuenta

Estandarizar

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j}$$

```
from sklearn.preprocessing import StandardScaler
X_esc = StandardScaler().fit_transform(X)
```

Todas las variables: media 0, desviación 1

El efecto en el notebook

Datos	ARI frente a perfiles reales
Sin escalar	≈ 0,52
Escalados	≈ 0,76

Mismo algoritmo, misma k: solo cambian las unidades

Qué escalador usar

Escalador	Cuándo
`StandardScaler`	Por defecto
`MinMaxScaler`	Variables acotadas
`RobustScaler`	Atípicos fuertes
`log1p` + estandarizar	Colas largas (gasto, visitas)

Escalar es ponderar

- Estandarizar = dar **el mismo peso** a cada variable
- ¿El gasto importa el doble? Multiplica su columna escalada
- Que el peso sea una **decisión**, no un accidente de unidades
- Interpreta siempre en unidades originales

2.3

k-means: algoritmo, supuestos y limitaciones

El objetivo de k-means

Encontrar k grupos que minimicen la **inercia**:

$$W = \sum_{c=1}^{k} \sum_{i \in C_c} \|x_i - \mu_c\|^2$$

μ_c: centroide (media) del grupo c

El algoritmo (Lloyd)

```
1. Elegir k centros iniciales (k-means++)
2. Asignar cada punto al centro más cercano
3. Mover cada centro a la media de sus puntos
4. Repetir 2-3 hasta que nada cambie
```

Siempre converge... a un **mínimo local**

En scikit-learn

```
from sklearn.cluster import KMeans
km = KMeans(n_clusters=4, n_init=10,
            random_state=0).fit(X_esc)
km.labels_           # segmento de cada cliente
km.cluster_centers_  # centros (escalados)
km.inertia_          # W
```

`n_init=10`: 10 arranques, se queda con el mejor

Supuestos implícitos

- Grupos **redondeados** (esféricos) tras escalar
- Tamaños y dispersiones **parecidos**
- Variables **numéricas** y comparables
- Asignación **dura**: cada punto, un solo grupo
- Fronteras **rectas** a medio camino entre centros

Dónde falla

Situación	Resultado
Medias lunas, formas alargadas	Las corta por la mitad
Anillos concéntricos	Imposible separarlos
Densidades distintas	El denso se parte
Atípicos	Desplazan centros

Alternativas: DBSCAN, mezclas gaussianas, jerárquico

Un caso suave en el notebook

Segmento k-means	dormidos	ocasionales
«dormidos»	208	0
«ocasionales»	167	375

Los dormidos "recientes" quedan más cerca del centro de ocasionales
→ k-means ve distancias a centros, no grupos

Errores frecuentes

- No escalar
- `n_init=1` y una única ejecución
- Leer el número de segmento como si significara algo
- Esperar que k-means te diga cuántos grupos hay

2.4

Elegir *k*: codo, silueta y criterio de negocio

La inercia siempre baja

- Más grupos → puntos más cerca de su centro
- Con $k = n$: $W = 0$
- Minimizar W no sirve para elegir k

Necesitamos criterios que midan otra cosa

Método del codo

k	**2**	**3**	**4**	**5**	**6**
Inercia	2.517	1.233	**574**	432	362

- Grandes caídas hasta $k = 4$; después, poco
- Problema: en datos reales el codo suele ser difuso

Coeficiente de silueta

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}$$

- $a(i)$: distancia media a **su** grupo
- $b(i)$: distancia media al grupo **vecino**
- ≈ 1 bien asignado · ≈ 0 frontera · < 0 mal asignado

Silueta en el notebook

k	2	3	4	5	6
Silueta	0,47	0,63	**0,64**	0,60	0,54

- Máximo en $k = 4$... pero $k = 3$ casi empata
- Cuando la técnica empata, **decide el negocio**

Otros criterios técnicos

- **Estabilidad**: otras semillas o submuestras → ARI entre particiones
- Calinski-Harabasz, Davies-Bouldin, estadístico *gap*
- **Tamaño mínimo**: un segmento del 1 % rara vez compensa

El criterio de negocio

1. ¿Puedo describir cada grupo en una frase?
2. ¿Tengo una acción **distinta** para cada uno?
3. ¿Es estable en el tiempo?
4. ¿Tiene tamaño suficiente para justificar la acción?

Ejemplo: aseguradora

- $k = 2$: mejor silueta → «un seguro» vs. «varios»: nada nuevo
- $k = 5$: silueta algo menor → grupos accionables
  - jóvenes solo con coche → venta cruzada de hogar
  - familias multiproducto → fidelización
- Se elige $k = 5$ **y se justifica**

2.5

Clustering jerárquico y dendrogramas

De abajo arriba

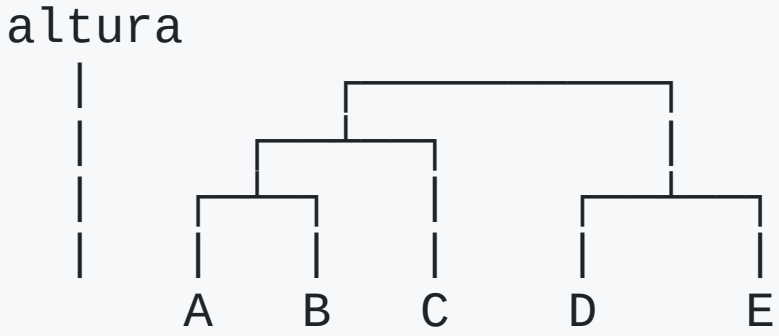
```
1. Cada punto es un grupo (n grupos)
2. Unir los dos grupos más cercanos
3. Repetir hasta tener un solo grupo
```

No hace falta fijar k al principio

Criterio de enlace

Enlace	Distancia entre grupos	Efecto
Simple	par más cercano	Cadenas largas
Completo	par más lejano	Grupos compactos
Promedio	media de pares	Compromiso
Ward	aumento de inercia	Compactos y equilibrados

Leer un dendrograma



- La **altura** de la unión = distancia de fusión
- Cortar horizontalmente = elegir número de grupos
- Saltos grandes → buen sitio para cortar

Trampa: lo horizontal no cuenta

- Dos hojas contiguas en el dibujo pueden estar lejos
- La distancia se lee en el **nodo** que las une
- El orden de las hojas es en parte arbitrario

En el notebook

```
Z = linkage(X_esc[muestra], method="ward")
dendrogram(Z, no_labels=True, color_threshold=12)
AgglomerativeClustering(n_clusters=4,
                        linkage="ward").fit_predict(X_esc)
```

Método	ARI frente a perfiles reales
k-means (k=4)	≈ 0,76
Jerárquico Ward (4)	≈ 0,84

Ventajas y límites

Ventajas	Límites
No exige k previo	Coste ~ n^2 en memoria
Estructura a varias escalas	Fusiones irreversibles
Determinista	Dendrograma ilegible con miles de hojas

Para el dibujo: usa una **muestra**

2.6

PCA: intuición geométrica y varianza explicada

64 dimensiones

- Dígitos manuscritos de 8 × 8 píxeles
- Cada imagen = un punto en $\mathbb{R}^{64}$
- Muchos píxeles redundantes (vecinos parecidos, bordes vacíos)
- ¿Podemos resumir en pocas variables?

La intuición: un plato inclinado

- Nube 3D con forma de plato: casi toda la variación en 2 direcciones
- **PC1**: dirección de máxima varianza
- **PC2**: máxima varianza perpendicular a PC1
- ... hasta p componentes

Proyectar = mirar la nube desde el mejor ángulo

Componentes y cargas

$$\mathrm{PC}_1 = w_{11}x_1 + w_{21}x_2 + \cdots + w_{p1}x_p$$

- w_{j1}: **cargas** → `pca.components_`
- Son vectores propios de la matriz de covarianzas
- Varianza de cada componente: valor propio λ_j

Varianza explicada

$$\frac{\lambda_j}{\sum_l \lambda_l}$$

```
pca = PCA().fit(digits.data)
var_acum = np.cumsum(pca.explained_variance_ratio_)
np.argmax(var_acum >= 0.9) + 1   # → 21
```

PC1 + PC2 ≈ 28,5 % · 21 componentes para el 90 %

Interpretar componentes

- Mira las cargas más grandes (en valor absoluto) y su signo
- Encuesta de 20 preguntas:
  - PC1: todas positivas → «satisfacción general»
  - PC2: precio (+) vs. atención (–)
- Finanzas: PC1 = «el mercado», PC2 = factor sectorial

¿Escalar antes de PCA?

- PCA maximiza varianza → depende de las unidades
- Euros + días + %: **estandariza**
- Píxeles (todos 0–16): no hace falta

Fortalezas y límites

Fortalezas	Límites
Rápido y determinista	Solo estructura **lineal**
`transform` para datos nuevos	Máx. varianza ≠ máx. relevancia
Interpretable (cargas)	Sensible a atípicos
Invertible (aprox.)	Componentes a veces difíciles de nombrar

2.7

t-SNE y UMAP: visualizar datos de alta dimensión

Cuando lo lineal no basta

- PCA en 2D: varios dígitos superpuestos
- No es que no se distingan: su estructura **no es lineal**
- Nueva meta: un mapa 2D que respete **quién es vecino de quién**

t-SNE en dos pasos

1. Original: probabilidad de que j sea vecino de i (p_{ij})
2. Mapa 2D: mover puntos hasta que $q_{ij} \approx p_{ij}$

$$\mathrm{KL}(P \,\|\, Q) = \sum_{i \neq j} p_{ij} \log \frac{p_{ij}}{q_{ij}}$$

Perplexity ≈ nº efectivo de vecinos (5–50)

Lo que t-SNE NO conserva

No interpretables:

- Distancias entre grupos
- Tamaños y densidades de los grupos

Cuidado:

- Puede crear grumos a partir de ruido
- Cambia con semilla y perplexity · sin `transform`

UMAP: la alternativa moderna

1. Grafo de k vecinos más cercanos en el espacio original
2. Disposición 2D cuyo grafo se parezca: atraer vecinos, repeler el resto

- `n_neighbors`: local ↔ global
- `min_dist`: lo apretados que quedan los grupos
- Librería `umap-learn`, misma interfaz `fit_transform`

PCA vs. t-SNE vs. UMAP

	PCA	t-SNE	UMAP
Tipo	Lineal	No lineal	No lineal
Conserva	Varianza global	Vecindad local	Local + algo global
Velocidad	Muy alta	Baja	Media-alta
Datos nuevos	Sí	No	Sí (aprox.)
Interpretable	Sí	No	No

Reglas de uso

- Úsalos para **explorar** y generar hipótesis
- Prueba varias perplexities / `n_neighbors` y semillas
- Con muchos datos: PCA a 30–50 dimensiones antes
- **No** hagas clustering sobre el mapa 2D
- Explica a tu audiencia qué significa (y qué no) la cercanía

2.8

Caso: segmentación RFM de clientes

RFM en tres números

- **R**ecency: días desde la última compra (menos = mejor)
- **F**requency: compras en el periodo
- **M**onetary: valor (gasto medio o total)

Se calcula con cualquier histórico de transacciones

El proceso

```
transacciones → RFM por cliente → log/atípicos → escalar
   → probar k (codo, silueta, estabilidad, jerárquico)
   → perfilar en unidades originales
   → nombrar + acción + métrica → medir (A/B)
```

Los cuatro segmentos del notebook

Segmento	R (días)	F (/año)	M (€)	Clientes
VIP ticket alto	31	11	253	367
Fieles recurrentes	15	26	59	373
Ocasionales	115	5	43	552
Dormidos	406	3	35	208

De segmentos a acciones

Segmento	Acción	Métrica
VIP	Beneficios no monetarios	Retención 12 meses
Fieles	Venta cruzada	Ticket medio
Ocasionales	Recordatorios por ciclo	Frecuencia trimestral
Dormidos	Reactivación con incentivo	% vuelve en 60 días

No regales margen a quien ya compra

Frontera difusa: ocasional ↔ dormido

- El segmento «ocasionales» incluye ~170 dormidos reales
- Lectura de negocio: la transición es **gradual**
- Solución práctica: segmento + regla
  - ocasional con recencia > 180 días → reactivación

Añadir variables con cuidado

- Tras escalar, cada variable **pesa lo mismo**
- Variable irrelevante → diluye distancias, baja la silueta
- Alternativa: segmentar con comportamiento, **describir** con el resto
- Recalcula periódicamente y mira transiciones entre segmentos

Tu entregable

1. Número de segmentos y justificación (técnica + negocio)
2. Ficha por segmento: nombre, tamaño, perfil, **una acción**
3. Un gráfico que muestre los segmentos

Máx. 2 páginas o 5 diapositivas

Resumen del módulo

Escalar · agrupar · elegir *k* con criterio · reducir dimensión · traducir a acciones

Próximo módulo: **Regresión y predicción**