Módulo I2

Regresión y predicción

Ciencia de Datos e IA Aplicada: de los datos a las decisiones

N2 · Intermedio

El caso de esta semana

- Un hospital quiere **anticipar la progresión de la diabetes** a un año
- 442 pacientes · 10 variables clínicas
- Objetivo: **priorizar seguimientos** con recursos limitados
- Dos preguntas distintas:
  - ¿Qué variables se asocian con la progresión? → **explicar**
  - ¿Cuánto progresará un paciente nuevo? → **predecir**

> Un coeficiente de regresión **no es un efecto causal** sin un diseño adecuado.

3.1

De la correlación a la recta de regresión; mínimos cuadrados

De la correlación a una regla

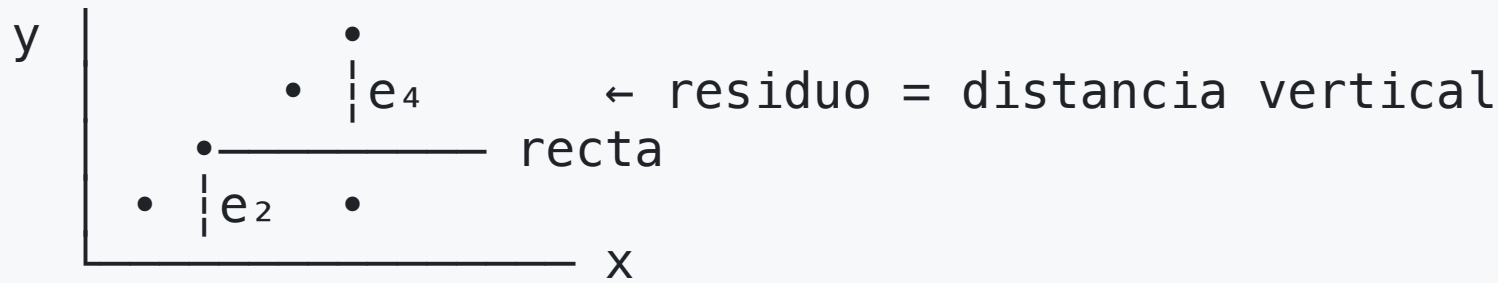
- Correlación IMC–progresión: $r = 0{,}59$
- Útil, pero no responde: *con IMC 30, ¿qué progresión espero?*
- Necesitamos una **regla de predicción**:

$$\hat{y} = \beta_0 + \beta_1 x$$

Símbolo	Significado
β_0	intercepto: predicción si $x = 0$
β_1	pendiente: cambio en $\hat{y}$ por unidad de x

Residuos: lo que la recta no explica

$$e_i = y_i - \hat{y}_i$$



- Positivo: el paciente progresa **más** de lo predicho
- Negativo: progresa **menos**

Mínimos cuadrados ordinarios (MCO)

$$\min_{\beta_0,\beta_1} \sum_{i=1}^{n} (y_i - \beta_0 - \beta_1 x_i)^2$$

¿Por qué al cuadrado?

- Positivos y negativos no se cancelan
- Los errores grandes pesan más
- Solución cerrada y única

La pendiente es una correlación con unidades

$$\hat{\beta}_1 = r_{xy} \frac{s_y}{s_x} \qquad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

- Variables estandarizadas → pendiente = correlación
- La recta pasa siempre por $(\bar{x}, \bar{y})$
- En regresión simple: $R^2 = r^2$

En el notebook: IMC → progresión

```
simple = sm.OLS(df["progresion"],
                sm.add_constant(df[["imc"]])).fit()
```

	Valor
Intercepto	−117,8
Pendiente IMC	**10,2**
R^2	0,34

- +1 punto de IMC → +10,2 puntos de progresión esperada
- IMC 30 → $-117{,}8 + 10{,}2 \times 30 \approx 189$

Tres errores frecuentes

1. **Extrapolar**: intercepto –117,8 = «IMC 0» (no existe)
2. **Pendiente ≠ fuerza**: depende de las unidades; mira r o R^2
3. **Pendiente ≠ causa**: compara pacientes distintos, no predice qué pasa si un paciente adelgaza

Ideas clave 3.1

- La regresión convierte una asociación en una **regla de predicción**
- MCO minimiza la suma de **residuos al cuadrado**
- Pendiente = diferencia media en y por unidad de x
- Asociación ≠ causalidad

Practica: notebook, secciones 1 y 2

3.2

Regresión múltiple: «manteniendo el resto constante»

Más de una variable

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p$$

- Mismo criterio: mínimos cuadrados
- Una recta → un **hiperplano**
- Forma matricial: $\hat{\beta} = (X^\top X)^{-1} X^\top y$

La frase clave

> β_j = diferencia esperada en y por +1 en x_j, **manteniendo constantes las demás variables del modelo**

Modelo	Coef. IMC
Solo IMC	10,2
10 variables	**5,7**

El IMC «se llevaba el mérito» de la presión y las analíticas

Los coeficientes dependen de los controles

Modelo	Coef. sexo	p-valor
IMC + sexo	−1,3	0,82
10 variables	**−23,1**	0,001

- Cada coeficiente responde a **una pregunta distinta**
- Falta un factor de confusión → **sesgo por variable omitida**

Lo que «constante» NO significa

- Solo controla lo que **está en el modelo**
- A veces es irreal: colesterol y LDL, $r = 0{,}90$
- No es una **intervención** sobre un paciente

> Para hablar de efectos causales: experimento aleatorizado o diseño causal explícito

Multicolinealidad

- Variables muy correlacionadas → el modelo no sabe repartir el mérito
- Síntomas: errores estándar grandes, signos «absurdos»
- Colesterol: coef. **–1,26** · LDL: **+0,80**

Variable	VIF
colesterol	54
ldl	36
imc	1,5

VIF > 5–10 → alarma · **la predicción conjunta no empeora**

Coeficientes estandarizados

- Crudos: dependen de las unidades (63,4 vs 5,7 no son comparables)
- Estandarizar: cambio en y por **1 desviación típica** de x_j

```
esc = StandardScaler().fit(X_train)
LinearRegression().fit(esc.transform(X_train), y_train).coef_
```

Mayores: colesterol (−44), triglicéridos (+33), IMC (+25), LDL (+25)

Ideas clave 3.2

- Coeficiente **parcial**: con el resto de variables del modelo fijas
- Cambia al añadir o quitar variables
- Multicolinealidad → coeficientes inestables, predicción estable
- Para comparar: estandariza · para causas: diseño causal

Practica: notebook, sección 3

3.3

Inferencia: errores estándar, p-valores, R^2

De la muestra a la población

$$y_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip} + \varepsilon_i$$

- β: valores desconocidos de la población
- $\hat{\beta}$: estimaciones con **nuestros 331 pacientes**
- Otra muestra → otros $\hat{\beta}$
- ¿Cuánto podrían variar? → **inferencia**

Error estándar e intervalo de confianza

Crece con…	Decrece con…
Ruido de los residuos	Tamaño de muestra ($1/\sqrt{n}$)
Multicolinealidad	Variabilidad de x_j

$$IC_{95\%} \approx \hat{\beta}_j \pm 2 \cdot EE$$

IMC: $5{,}73 \pm 2 \times 0{,}85$ → **[4,06; 7,41]**

Estadístico t y p-valor

$$H_0 : \beta_j = 0 \qquad t = \frac{\hat{\beta}_j}{EE(\hat{\beta}_j)}$$

Variable	coef	p
imc	5,73	< 0,001
presion	1,31	< 0,001
trigliceridos	63,4	< 0,001
hdl	0,43	0,62
glucosa	0,11	0,73

Cómo NO leer un p-valor

- $p = 0{,}3 \neq$ «no influye» (muestra pequeña, colinealidad, no linealidad)
- $p < 0{,}05 \neq$ «efecto grande»
- $p < 0{,}05 \neq$ «efecto causal»
- 10 p-valores → más falsos positivos (módulo 04)

Traduce siempre a magnitud de negocio + intervalo

R^2 y R^2 ajustado

$$R^2 = 1 - \frac{\sum(y_i - \hat{y}_i)^2}{\sum(y_i - \bar{y})^2}$$

$$R^2_{aj} = 1 - (1 - R^2)\frac{n-1}{n-p-1}$$

- Notebook: $R^2 = 0{,}52 \cdot R^2_{aj} = 0{,}50$
- R^2 **nunca baja** al añadir variables
- R^2 en train ≠ calidad predictiva (→ 3.6)

Confianza vs. predicción

Paciente con IMC 30 → predicción 189

Intervalo	¿Sobre qué?	Rango
Confianza	Media de pacientes con IMC 30	≈ 181–197
Predicción	**Un** paciente concreto	**66–312**

Para decisiones individuales, manda el **intervalo de predicción**

Ideas clave 3.3

- EE mide la incertidumbre; IC ≈ $\hat{\beta} \pm 2\,EE$
- El p-valor no mide importancia ni causalidad
- R^2 ajustado penaliza variables; ninguno sustituye a validar fuera de muestra
- El intervalo de predicción individual es ancho

Practica: notebook, sección 3 (`ols.summary()`)

3.4

Supuestos y diagnóstico de residuos

¿Para qué sirven los supuestos?

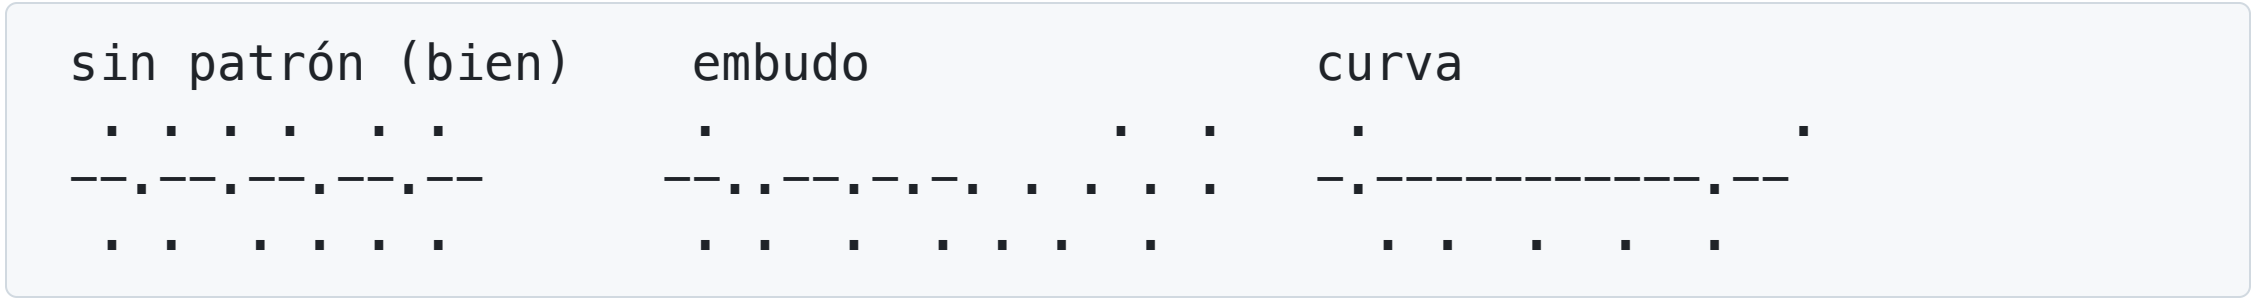
- MCO **siempre** devuelve una recta
- **Predecir** + validar fuera de muestra → los supuestos importan menos
- **Explicar** (coeficientes, p-valores, intervalos) → imprescindibles

LINE

Supuesto	Si falla...
Linealidad	sesgo, errores sistemáticos
Independencia	falsa precisión (EE pequeños)
Normalidad	p-valores dudosos con n pequeño
Equal variance	EE e intervalos incorrectos

La independencia es una cuestión de **diseño**

Residuos vs. ajustados



- **Embudo** → heterocedasticidad
- **Curva** → falta un término no lineal

QQ-plot y contrastes

- QQ-plot: cuantiles de residuos vs. normal → buscamos **la diagonal**
- Notebook: QQ-plot casi recto · Jarque-Bera p = 0,38
- Dispersión menor en predicciones bajas · Breusch-Pagan p = 0,05

> Los tests ayudan, pero **mira siempre las gráficas**

Puntos influyentes

- **Apalancamiento**: x extremo
- **Residuo grande**: mal ajustado
- Ambos → **distancia de Cook** alta

```
cook = ols.get_influence().cooks_distance[0]
```

¿Error de datos? → corregir · ¿Caso real? → informar con y sin él

Qué hacer si algo falla

Síntoma	Remedio
Curva	$\log x$, x^2, interacciones
Embudo	$\log y$, EE robustos (`cov_type="HC3"`)
Dependencia	modelos para grupos / tiempo
Colas pesadas	revisar atípicos, regresión robusta

Ideas clave 3.4

- LINE importa sobre todo para **interpretar**
- Residuos = ruido: sin curva, sin embudo
- Revisa los residuos, no la distribución de y
- Los puntos influyentes se investigan, no se borran

Practica: notebook, sección 4

3.5

Variables categóricas, interacciones y transformaciones

Lineal en los coeficientes

- La regresión es lineal en los β, **no** necesariamente en las variables
- Tres herramientas:
    i. Variables indicadoras
    ii. Interacciones
    iii. Transformaciones

Variables indicadoras (dummies)

región	Centro	Sur
Norte (referencia)	0	0
Centro	1	0
Sur	0	1

- k categorías → $k - 1$ columnas
- Coef. «Sur» = diferencia Sur – Norte
- `pd.get_dummies(drop_first=True)` · `C(region)`
- Notebook: sexo = –23,1 frente al grupo 0

Interacciones

$$\hat{y} = \beta_0 + \beta_1 \,\text{imc} + \beta_2 \,\text{edad} + \beta_3 \,(\text{imc} \times \text{edad})$$

Pendiente del IMC $= \beta_1 + \beta_3 \cdot \text{edad}$

- **Centra** antes de multiplicar
- Incluye los efectos principales
- Ejercicio 2: $\beta_3 = 0{,}05$, p = 0,36 → sin evidencia

Logaritmos: cómo cambia la lectura

Modelo	+… en x	→ en y
$y \sim x$	+1 unidad	$+\beta_1$ unidades
$y \sim \log x$	+1 %	$+\beta_1/100$ unidades
$\log y \sim x$	+1 unidad	$\approx +100\beta_1$ %
$\log y \sim \log x$	+1 %	$+\beta_1$ %

Ojo: `triglicéridos` ya está en log

- Rango 3,3–6,1 → escala logarítmica
- Coef. 63,4 por **+1 en el log** (×2,7 los triglicéridos)
- Lectura útil: +10 % triglicéridos → $63{,}4 \times 0{,}095 \approx$ **+6 puntos**

Polinomios

- x^2 captura curvas (rendimientos decrecientes)
- Grado 2 con 10 variables → **65 términos**
- Mucha flexibilidad... ¿demasiada? → 3.6

Ideas clave 3.5

- Categóricas: $k - 1$ indicadoras frente a una referencia
- Interacción: la pendiente de una depende de otra
- Logaritmos: efectos porcentuales, arreglan asimetrías
- Comunica en la escala original («≈ 14 %», no «0,15»)

Practica: notebook, ejercicio 2

3.6

Sobreajuste, train/test y validación cruzada

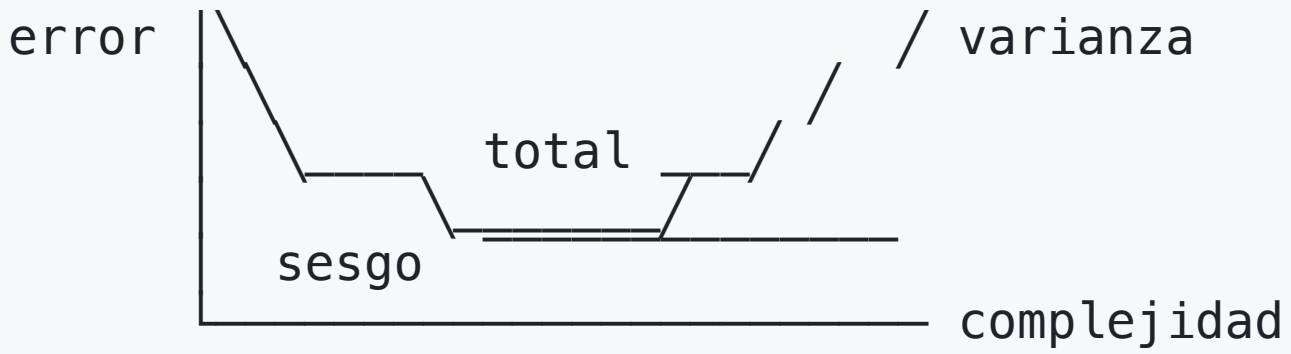
Explicar ≠ predecir

- Hasta ahora: ajuste con los **mismos** datos
- El hospital lo usará con pacientes **nuevos**
- Más flexibilidad → mejor ajuste… **también al ruido**

	Train	Nuevos datos
Infraajuste	malo	malo
Buen ajuste	bueno	bueno
Sobreajuste	muy bueno	**malo**

Sesgo y varianza

$$\text{Error} = \text{Sesgo}^2 + \text{Varianza} + \text{Ruido}$$



Partición train/test

```
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.25, random_state=42)
```

- Train: 331 pacientes · Test: 111
- **El test se usa una vez, al final**
- Problema: depende de la suerte del reparto

Validación cruzada (k-fold)

```
Iter. 1: [VAL][ T ][ T ][ T ][ T ]
Iter. 2: [ T ][VAL][ T ][ T ][ T ]
  ...
Iter. 5: [ T ][ T ][ T ][ T ][VAL]
```

- Media de k evaluaciones → más estable
- CV para **elegir** · test para **confirmar**
- Preprocesado **dentro** del pipeline (evita fugas)

El caso del notebook

Modelo	R^2 CV	R^2 test	MAE test
Lineal	0,480	0,485	41,5
Polinómica grado 2	**0,166**	0,424	44,0
Polinómica + Ridge	0,428	0,500	42,2
Lasso	0,480	0,487	41,5

Polinómica: R^2 train **0,60** → CV **0,17** = sobreajuste

Métricas de regresión

Métrica	Fórmula	Lectura
MAE	$\frac{1}{n}\sum\lvert y_i - \hat{y}_i\rvert$	error típico en unidades de y
RMSE	$\sqrt{\frac{1}{n}\sum(y_i - \hat{y}_i)^2}$	penaliza errores grandes
R^2 test	$1 - \frac{SSE}{SST}$	puede ser < 0

Siempre contra una referencia

Estrategia	MAE test
Predecir siempre la media	65,5
Modelo Lasso	**41,5**

- −37 % de error
- Seguimiento al 20 %: el modelo captura el **68 %** del top real (azar: 20 %)

Ideas clave 3.6

- Juzga el modelo con datos **no vistos**
- Sobreajuste = brecha train ↔ validación
- CV para elegir, test una sola vez
- Compara con una referencia ingenua y tradúcelo a la decisión

Practica: notebook, secciones 5 y 6; ejercicios 1 y 4

3.7

Regularización: Ridge y Lasso

Ponerle precio a la complejidad

$$\min_{\beta} \underbrace{\sum_{i}(y_i - \hat{y}_i)^2}_{\text{ajuste}} + \underbrace{\alpha \cdot P(\beta)}_{\text{complejidad}}$$

$P(\beta)$ = penalización por el tamaño de los coeficientes

α	Resultado
0	MCO
pequeño	riesgo de sobreajuste
grande	coeficientes → 0, infraajuste

Ridge (L2)

$$P(\beta) = \sum_j \beta_j^2$$

- Encoge **todos** los coeficientes, casi nunca a 0
- Reparte el peso entre variables correlacionadas
- Notebook (polinómica): R^2 CV 0,17 → **0,43** · test 0,42 → **0,50**

Lasso (L1)

$$P(\beta) = \sum_j |\beta_j|$$

- Puede poner coeficientes **exactamente a 0** → selección
- Notebook: α ≈ 0,11 · descarta **hdl** · MAE 41,5

```
L1: rombo ◇ → esquinas en los ejes → ceros
L2: círculo ○ → sin esquinas → no hay ceros
```

Ridge vs. Lasso

	Ridge	Lasso
Coeficientes	encoge	encoge y anula
Selección	no	sí
Correlacionadas	reparte	elige una
Brilla con…	muchos efectos pequeños	pocos relevantes

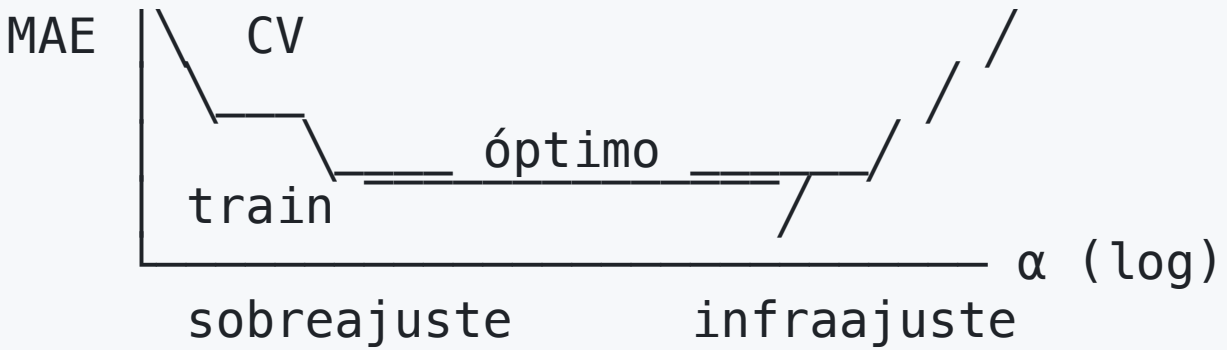
Elastic Net = mezcla de ambas

Estandarizar es obligatorio

- La penalización suma coeficientes de **distintas** variables
- Edad en meses → coeficiente 12 veces menor → penalización distinta
- Solución: misma escala para todas

```
make_pipeline(StandardScaler(), LassoCV(cv=5, random_state=0))
```

Elegir α con validación cruzada



Ejercicio 3: óptimo por CV en α ≈ 35 (polinómica + Ridge)

Interpretar con cuidado

- Coeficientes **sesgados hacia 0** a propósito
- Lasso elige entre correlacionadas de forma inestable
- Sin p-valores clásicos tras seleccionar
- Conservada por Lasso ≠ causa

> Regularizar es para **predecir**; para **explicar**, solo orientativo

Ideas clave 3.7

- Penalización controlada por α
- Ridge encoge · Lasso encoge y selecciona
- Estandariza y elige α por validación cruzada
- Predicción sí; interpretación causal, no

Practica: notebook, sección 5 y ejercicio 3

Resumen del módulo

Ajustar · interpretar · diagnosticar · validar · regularizar · **decidir**

Caso práctico: memorando para la dirección médica