Módulo I6

Analítica predictiva con series temporales

Ciencia de Datos e IA Aplicada: de los datos a las decisiones

N2 · Intermedio

8.1

Series temporales en la empresa: demanda, ventas, capacidad

Detrás de cada decisión, una serie temporal

- ¿Cuántos yogures pide cada tienda el martes?
- ¿Cuántas personas en el turno del sábado?
- ¿Qué capacidad contratamos en la nube?
- ¿Qué presupuesto de ventas comprometemos?

Serie temporal: observaciones $y_1, y_2, \ldots, y_T$ a intervalos regulares.

El **orden** es información: nunca se baraja.

El horizonte lo dicta la decisión

Horizonte	Decisión	Granularidad
Corto (horas–semanas)	turnos, reposición	horaria / diaria
Medio (1–18 meses)	compras, presupuesto	semanal / mensual
Largo (años)	almacén, planta	trimestral / anual

Cuanto más lejos, más se agrega y más pesa el juicio experto.

Pronóstico ≠ objetivo ≠ plan

	Pregunta	Ejemplo
Pronóstico	¿Qué pasará si nada cambia?	10.000 uds.
Objetivo	¿Qué nos gustaría?	12.000 uds.
Plan	¿Qué haremos?	campaña en marzo

Si "ajustas" el pronóstico al objetivo, deja de servir para planificar.

¿Qué hace predecible una serie?

1. Entendemos los factores que la mueven
2. Hay datos suficientes (varios ciclos completos)
3. El futuro se parecerá al pasado
4. El pronóstico no altera el resultado

Consumo eléctrico: muy predecible · precio de una acción mañana: casi nada

Series temporales en pandas

```
co2 = sm.datasets.co2.load_pandas().data["co2"]   # semanal
serie = co2.resample("MS").mean().interpolate()   # mensual
serie.index.freq = "MS"
```

- `DatetimeIndex` + frecuencia declarada
- Ventas → agregar con **suma**; concentraciones y precios → **media**
- Caso del módulo: CO_2 en Mauna Loa, 526 meses (1958–2001)

El flujo de trabajo del módulo

```
Datos → Visualizar y descomponer → Estacionariedad / ACF
      → Partición temporal → Referencias ingenuas
      → Modelos (Holt–Winters, SARIMA)
      → Backtesting → Diagnóstico de residuos
      → Pronóstico final + intervalo
```

Un pronóstico útil siempre lleva su **incertidumbre**.

8.2

Componentes y descomposición (STL)

Tres movimientos superpuestos

- **Tendencia** T_t: evolución a largo plazo
- **Estacionalidad** S_t: patrón con periodo fijo m
  - 12 (mensual), 7 (diario), 24 (horario)
- **Residuo** R_t: lo que queda; idealmente, ruido

¿Aditiva o multiplicativa?

$$y_t = T_t + S_t + R_t \qquad\qquad y_t = T_t \times S_t \times R_t$$

Si la oscilación estacional...	Usa
tiene amplitud constante	aditiva
crece con el nivel	multiplicativa

Truco: $\log(T \cdot S \cdot R) = \log T + \log S + \log R$

Cómo funciona STL

1. Estima la tendencia con suavizado local (*loess*)
2. Resta la tendencia; suaviza cada "mes" a lo largo de los años → estacionalidad
3. Resta la estacionalidad y vuelve a estimar la tendencia
4. Repite hasta estabilizar

Ventajas: estacionalidad que **evoluciona**, sin perder extremos, versión **robusta** a atípicos

STL en el notebook

```
from statsmodels.tsa.seasonal import STL
stl = STL(serie, period=12).fit()
stl.plot()
```

- Tendencia: subida casi lineal, algo acelerada
- Estacionalidad: ciclo anual de ~6 ppm (vegetación del hemisferio norte)
- Residuo: pequeño, sin patrón

¿Cuánta estacionalidad hay?

$$F_S = \max\left(0,\ 1 - \frac{\mathrm{Var}(R_t)}{\mathrm{Var}(S_t + R_t)}\right)$$

- $F_S \approx 1$: estacionalidad fuerte
- $F_S \approx 0$: débil
- Igual para la tendencia, con $T_t + R_t$

Con miles de productos: clasifica y elige modelo por grupo

Usos en la empresa

- **Desestacionalizar**: ¿vamos mejor o peor *de lo normal* para esta época?
- **Detectar anomalías**: residuos enormes = días raros
- **Comunicar**: la tendencia limpia se entiende en un comité

Hotel: agosto +5 % vs. julio… pero lo normal es +12 % → la tendencia cae

Errores frecuentes

- Periodo mal elegido (datos diarios: 7 **y** 365 → MSTL)
- Aditiva con oscilaciones crecientes → residuo en "embudo"
- Usar STL como si fuera un modelo de pronóstico

8.3

Estacionariedad, diferenciación y autocorrelación

¿Qué es una serie estacionaria?

- Media constante
- Varianza constante
- Relación entre y_t e y_{t-k} depende solo de k

Si tapas el eje del tiempo, no sabrías en qué época estás.

Tendencia o estacionalidad ⇒ **no** estacionaria

Diferenciar para estabilizar

$$\nabla y_t = y_t - y_{t-1} \qquad \nabla_{12}\, y_t = y_t - y_{t-12}$$

- Regular: elimina la tendencia
- Estacional: elimina la estacionalidad
- Log + diferencia ≈ tasa de crecimiento
- Casi nunca hace falta más de $d = 1, D = 1$

Prueba ADF (Dickey-Fuller aumentada)

H_0: **no** estacionaria · p-valor < 0,05 ⇒ estacionaria

Serie de CO_2	p-valor ADF
Original	0,9989
1.ª diferencia	0,0001
1.ª dif. + dif. estacional	< 0,0001

p-valor alto ≠ "es estacionaria" (es al revés)

ACF y PACF

$$r_k = \frac{\sum_{t=k+1}^{T}(y_t - \bar{y})(y_{t-k} - \bar{y})}{\sum_{t=1}^{T}(y_t - \bar{y})^2}$$

- **ACF**: correlación con la serie desplazada k periodos
- **PACF**: lo mismo, descontando los retardos intermedios
- Bandas: $\pm 1{,}96/\sqrt{T}$

Cómo leer los correlogramas

Patrón	Indica
ACF decae muy lento	tendencia: diferencia
Picos en 12, 24, 36	estacionalidad anual
PACF se corta en p	AR(p)
ACF se corta en q	MA(q)

Siempre sobre la serie **ya diferenciada**

El caso del CO_2

```
d = serie.diff().diff(12).dropna()
plot_acf(d, lags=36); plot_pacf(d, lags=36)
```

- Pico negativo en el retardo 1 → MA regular
- Pico en el retardo 12 → MA estacional
- Encaja con $(1,1,1)(0,1,1)_{12}$

Errores frecuentes

- Leer la ADF al revés
- Identificar ARIMA con la ACF de la serie original
- Sobrediferenciar (pico ≈ −0,5 en el retardo 1)
- Olvidar `dropna()` tras diferenciar

8.4

Métodos de referencia: ingenuo, estacional, deriva

La pregunta incómoda

> ¿Qué error cometería la regla más tonta posible?

- Si tu modelo no la mejora, no aporta valor
- En series, las referencias son **difíciles de batir**
- Se calculan **solo** con el entrenamiento

Cuatro referencias

Método	Pronóstico
Ingenuo	$\hat{y}_{T+h} = y_T$
Ingenuo estacional	mismo mes del último año
Deriva	$y_T + h\,\frac{y_T - y_1}{T-1}$
Estacional + deriva	mismo mes del año pasado + subida media anual

En código

```
ingenuo = np.repeat(train.iloc[-1], H)
ingenuo_estacional = np.tile(train.iloc[-12:].values, H // 12)
deriva = train.iloc[-1] + (train.iloc[-1] - train.iloc[0]) \
         / (len(train) - 1) * np.arange(1, H + 1)
subida_anual = (train.iloc[-12:].values
                - train.iloc[-24:-12].values).mean()
```

Resultados en el test de 24 meses

Método	MAE (ppm)
Ingenuo	2,42
Deriva	1,91
Ingenuo estacional	1,88
Estacional + deriva	0,56
SARIMA	0,36
Holt-Winters	0,24

Medir la mejora: *skill score*

$$\text{Skill} = 1 - \frac{\text{error del modelo}}{\text{error de la referencia}}$$

- Holt-Winters vs. estacional + deriva: $1 - 0{,}24/0{,}56 \approx 0{,}57$
- Skill < 0 ⇒ el modelo es **peor** que la referencia
- "57 % menos error" se entiende mejor que "0,24 ppm"

Por qué son imprescindibles

- Dan **escala** al error
- Detectan modelos **inútiles**
- Detectan **errores de código** (desfases, fugas)
- Son **explicables**: "lo del año pasado + 3 %"

Moda: modelo 18 % MAPE vs. "lo de la temporada pasada" 19 % → no compensa

8.5

Suavizado exponencial y Holt-Winters

Entre el ingenuo y la media

- Ingenuo: solo la última observación
- Media: todo el pasado pesa igual
- **Suavizado exponencial**: todo el pasado, con pesos que **decrecen exponencialmente**

Suavizado exponencial simple

$$\ell_t = \alpha\, y_t + (1-\alpha)\, \ell_{t-1} \qquad \hat{y}_{t+h} = \ell_t$$

α	hoy	hace 1	hace 2	hace 5
0,8	0,80	0,16	0,03	0,0003
0,2	0,20	0,16	0,13	0,07

α alto: olvida deprisa · α bajo: promedia mucho

Holt: nivel + pendiente

$$\ell_t = \alpha\, y_t + (1-\alpha)(\ell_{t-1} + b_{t-1})$$
$$b_t = \beta\,(\ell_t - \ell_{t-1}) + (1-\beta)\, b_{t-1}$$

Tendencia amortiguada ($0 < \phi < 1$):

$$\hat{y}_{t+h} = \ell_t + (\phi + \phi^2 + \cdots + \phi^h)\, b_t$$

Holt-Winters aditivo

$$s_t = \gamma\,(y_t - \ell_{t-1} - b_{t-1}) + (1-\gamma)\,s_{t-m}$$

$$\hat{y}_{t+h} = \ell_t + h\,b_t + s_{t+h-m(k+1)}$$

- Cada componente: "lo que dice el dato nuevo" vs. "lo que creíamos"
- α, β, γ: velocidad de olvido de nivel, tendencia y estacionalidad

Aditivo vs. multiplicativo

	Estacionalidad	Ejemplo
Aditivo	+3 ppm en mayo	CO_2
Multiplicativo	×1,35 en diciembre	ventas que crecen

Multiplicativo: solo valores **positivos** (sin ceros)

En el notebook

```
hw = ExponentialSmoothing(train, trend="add", seasonal="add",
                          seasonal_periods=12).fit()
pred_hw = hw.forecast(24)
```

- Test 24 meses: **MAE 0,24 ppm** (el mejor)
- Backtesting 12 meses: **0,45 ppm** (empate con SARIMA)
- Los parámetros se **estiman**, no se fijan a ojo

La familia ETS

Error · **T**endencia · e**S**tacionalidad

- Error: aditivo / multiplicativo
- Tendencia: ninguna / aditiva / amortiguada
- Estacionalidad: ninguna / aditiva / multiplicativa

Aporta intervalos probabilísticos y selección automática por AIC (`ETSModel`, `AutoETS`)

Errores frecuentes

- Estacionalidad aditiva con oscilaciones que crecen
- Fijar α "a ojo"
- Esperar que anticipe cambios de régimen
- Multiplicativo con ceros en la serie

8.6

Modelos ARIMA y SARIMA

Las tres piezas

Pieza	Idea	Ejemplo
AR(p)	depende de valores pasados	incidencias abiertas
I(d)	se diferencia d veces	eliminar tendencia
MA(q)	depende de errores pasados	efecto de un *shock*

MA aquí ≠ media móvil para suavizar

ARIMA(p, d, q)

Sobre la serie diferenciada y'_t:

$$y'_t = c + \sum_{i=1}^{p} \phi_i \, y'_{t-i} + \sum_{j=1}^{q} \theta_j \, \varepsilon_{t-j} + \varepsilon_t$$

Modela la **autocorrelación**, no los componentes

SARIMA: añadir la capa estacional

$$\mathrm{SARIMA}(p,d,q)(P,D,Q)_m$$

- (p,d,q): retardos 1, 2, ...
- $(P,D,Q)_m$: retardos m, $2m$, ...
- "Modelo de las aerolíneas": $(0,1,1)(0,1,1)_{12}$

El modelo del notebook: $(1,1,1)(0,1,1)_{12}$

Coeficiente	Estimación	p-valor
ϕ_1 (AR)	0,28	0,012
θ_1 (MA)	−0,60	< 0,001
Θ_1 (MA estacional)	−0,85	< 0,001

Θ_1 cerca de −1 ⇒ patrón estacional muy estable

Cómo elegir los órdenes

1. Transformar (log) si la varianza crece
2. d, D con ADF y gráfico
3. p, q, P, Q con ACF / PACF
4. Comparar por AIC: $\mathrm{AIC} = -2 \log L + 2k$
5. Validar con backtesting y residuos

AIC solo comparable con **igual** d, D y transformación

En código

```
sarima = SARIMAX(train, order=(1, 1, 1),
                 seasonal_order=(0, 1, 1, 12)).fit(disp=False)
fc = sarima.get_forecast(24)
fc.predicted_mean           # pronóstico
fc.conf_int(alpha=0.05)     # IC 95 %
sarima.plot_diagnostics()
```

Diagnóstico de residuos

Residuos ≈ **ruido blanco**:

- Media cero, varianza constante
- Sin autocorrelación (Ljung-Box: p-valor alto = bien)
- Histograma y Q-Q cercanos a la normal

Si queda autocorrelación, queda información sin usar

Intervalos que se ensanchan

- Cada paso usa predicciones anteriores, también inciertas
- Paseo aleatorio: error típico a h pasos $\propto \sigma\sqrt{h}$
- CO_2 (ej. 1): ±0,6 ppm el mes 1 → ±1,8 ppm el mes 24

Comunica el intervalo **del horizonte que se va a usar**

8.7

Validación temporal y métricas (MAE, MAPE)

Partición aleatoria = fuga del futuro

- Entrenar con marzo para "predecir" febrero
- Evaluación demasiado optimista
- En producción nunca tendrás esa ventaja

Regla: el entrenamiento siempre es **anterior** a la prueba

Partición temporal

```
H = 24
train, test = serie[:-H], serie[-H:]
```

- También para escalados, imputaciones, selección de variables
- Elige con *backtesting*; reserva el test final

Backtesting de origen móvil

```
1994: [====== entrenamiento ======][test 12m]
1995: [======= entrenamiento =======][test 12m]
1996: [======== entrenamiento ========][test 12m]
 ...
2000: [========== entrenamiento ==========][test 12m]
```

Ventana **expansiva** (notebook) o **deslizante** (últimos N años)

Resultados del backtesting (7 orígenes)

Modelo	MAE medio (ppm)
Ingenuo estacional	1,71
Holt-Winters	0,45
SARIMA	0,44

- El test único exageraba la ventaja de Holt-Winters
- El error varía entre orígenes: 1998 fue difícil para todos

Métricas de error

$$\mathrm{MAE} = \frac{1}{n}\sum |e_t| \qquad \mathrm{RMSE} = \sqrt{\frac{1}{n}\sum e_t^2}$$

$$\mathrm{MAPE} = \frac{100}{n}\sum \left|\frac{e_t}{y_t}\right| \qquad \mathrm{MASE} = \frac{\mathrm{MAE}}{\mathrm{MAE}_{\text{ingenuo}}}$$

¿Cuál usar?

Métrica	Unidades	Problema	Cuándo
MAE	de la serie	no compara escalas	una serie
RMSE	de la serie	sensible a atípicos	errores grandes caros
MAPE	%	explota con ceros	series lejos de 0
MASE / WAPE	relativo	menos intuitiva	muchas series

La métrica refleja el coste

- ¿Quedarse corto cuesta el triple que pasarse? → pérdida asimétrica o cuantiles
- *E-commerce*: MAPE inflado por artículos que venden 0–1 uds.
- Elegir la métrica es una decisión **de negocio**

Errores frecuentes

- `KFold` o partición aleatoria en series
- Calcular variables con toda la serie antes de partir
- Elegir con el test y reportar ese mismo error
- Comparar modelos en horizontes distintos

8.8

Variables externas, múltiples series y modelos de machine learning

Más allá del modelo univariante

- Hasta ahora: la serie solo mira **su propio pasado**
- En la empresa conocemos más: promociones, festivos, meteorología
- Y casi nunca hay **una** serie, sino miles

SARIMAX: variables exógenas

$$y_t = \beta_1 x_{1,t} + \cdots + \beta_k x_{k,t} + \eta_t, \quad \eta_t \sim \text{SARIMA}$$

```
SARIMAX(ventas, exog=df[["promo", "festivo"]], ...)
modelo.forecast(14, exog=futuro[["promo", "festivo"]])
```

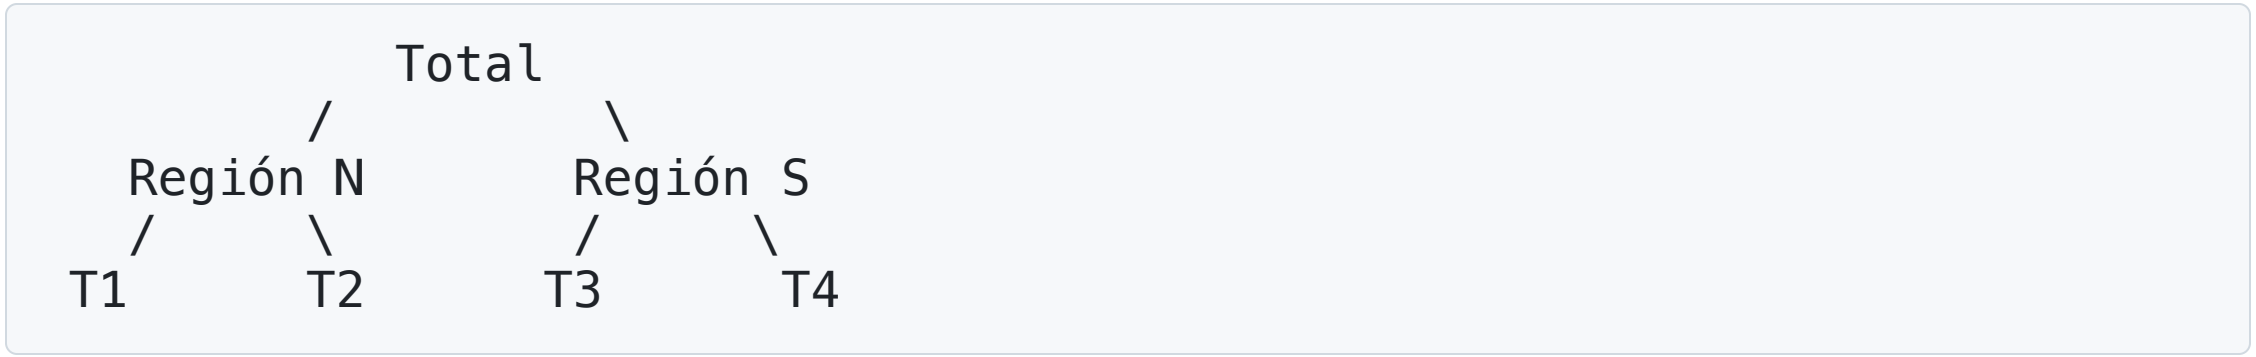
⚠️ Necesitas los valores **futuros** de las exógenas

Muchas series: local vs. global

Enfoque	Qué es	Cuándo
Local	un modelo por serie (ETS, ARIMA)	series largas y regulares
Global	un modelo para todas (ML)	series cortas, productos nuevos

statsforecast: `AutoETS`, `AutoARIMA` para miles de series

Jerarquías y coherencia



La suma de las tiendas debe cuadrar con el total → **reconciliación jerárquica**

Machine learning: la serie como tabla

ventas	lag_1	lag_7	media_7d	día	promo
152	140	149	143,6	dom	0

- Retardos, ventanas móviles (**solo pasado**), calendario, exógenas
- LightGBM, XGBoost, redes; skforecast, mlforecast

¿Recursiva o directa? ¿Cuándo compensa?

- **Recursiva**: predice $t+1$ y lo usa como retardo para $t+2$
- **Directa**: un modelo por horizonte
- ML gana con: muchas series, muchas exógenas, no linealidades
- Una serie mensual corta: los clásicos suelen bastar

Modelos fundacionales y combinación

- Preentrenados con millones de series: TimeGPT, Chronos, TimesFM
- Pronóstico *zero-shot*… que se evalúa **igual**: backtesting + referencias
- **Promediar** modelos distintos suele mejorar la precisión

Cierre del módulo y caso práctico

- Pronóstico a 24 meses con intervalo (ejercicio 1)
- Error esperado según el backtesting
- Mejora frente a la referencia ingenua
- 3 frases para un responsable no técnico

Opcional: aplica el flujo a una serie de tu empresa (ejercicio 4)