I8 · Del notebook a producción

Paquete · FastAPI · Tests · Docker · CI · MLflow · Deriva

AI Surfer · N2 Intermedio

Por qué este módulo

- «Sé entrenar modelos» ≠ «sé entregar modelos»
- Ofertas reales (oct. 2026): *FastAPI, Docker, CI/CD, MLflow, monitorización* aparecen en casi todas las de ML/AI Engineer
- Al terminar: un repositorio completo para tu portafolio

Mapa del módulo

1. Del notebook al paquete
2. Pipelines sin fugas + ficha del modelo
3. FastAPI
4. Tests para ML
5. Docker
6. CI/CD
7. MLflow
8. Deriva
9. Agentes de código

8.1 · El notebook no se despliega

- Estado oculto (orden de celdas)
- No se importa ni se testea
- Regla: **si se ejecuta dos veces, es una función**

```
src/tiendasur_churn/  datos.py · modelo.py · entrenar.py · api.py
tests/  ·  Dockerfile  ·  .github/workflows/ci.yml
```

8.2 · El pipeline ES el modelo

```
Pipeline([("prep", ColumnTransformer(...)),
          ("modelo", HistGradientBoostingClassifier())])
```

- `fit` ajusta el preprocesado **solo con train** → sin fugas
- La API recibe datos crudos → mismo preprocesado
- `handle_unknown="ignore"` → una categoría nueva no tumba el servicio

La ficha del modelo

Campo	Para qué
versión	rastrear decisiones
métricas	comparar candidatos
huella de datos	detectar reentrenos con datos distintos
versiones librerías	reconstruir el entorno
uso previsto, limitaciones	gobernanza y auditoría

8.3 · FastAPI en 4 decisiones

1. **Contrato** con Pydantic → `422` antes del modelo
2. Modelo cargado **una vez** (`lifespan`)
3. `/health` para el orquestador
4. **Versión** en cada respuesta + **logs JSON** sin datos personales

Documentación automática en `/docs`

8.4 · Tres tipos de test

Datos	Modelo	API
esquema, rangos	AUC ≥ umbral	`/health`
categorías	reproducible	`/predict`
	comportamiento	`422` si inválido

Los tests crean lo que necesitan: en el CI no hay artefactos

8.5 · Docker

- Dependencias **antes** que el código (caché de capas)
- `python:3.12-slim`, versiones fijadas
- `USER app` (nunca root)
- `.dockerignore` con `.env`
- Secretos **al ejecutar**, nunca con `COPY`

8.6 · CI/CD

push / PR → lint → tests → entrenar → imagen → *(CD)* registro → servicio

Dónde desplegar:

- Contenedor gestionado: Cloud Run · App Runner/ECS · Azure Container Apps
- Plataforma ML: SageMaker · Vertex AI · Azure ML · Databricks
- Kubernetes (equipos de plataforma)

8.7 · MLflow

- Parámetros · métricas · etiquetas · artefactos
- Comparar y reproducir ejecuciones
- Registro de modelos: promover y volver atrás

En la práctica: profundidad ilimitada + learning rate alto → **sobreajuste visible en la tabla**

8.8 · Se degrada sin errores

Señal	Avisa en
latencia, errores	segundos
PSI entradas / predicciones	días
métrica real	semanas

PSI: < 0,1 estable · 0,1–0,2 vigilar · > 0,2 deriva

Primero diagnostica (¿cambio real o error de datos?)

8.9 · Agentes de código con control

- Tests = especificación
- `AGENTS.md` / `CLAUDE.md`: comandos y reglas
- Intención antes que código (*spec-driven*)
- Revisa el diff · permisos mínimos

Entregable

Repo en GitHub · CI en verde · imagen que arranca · README en 3 comandos

Es tu pieza de portafolio de MLOps